

Neuronové sítě

Doc. RNDr. Iveta Mrázová, CSc.

Katedra teoretické informatiky

Matematicko-fyzikální fakulta

Univerzity Karlovy v Praze

Neuronové sítě

- Vrstevnaté neuronové sítě –
- analýza vlastností –

Doc. RNDr. Iveta Mrázová, CSc.

Katedra teoretické informatiky

Matematicko-fyzikální fakulta

Univerzity Karlovy v Praze

Kolmogorovova věta - 1957


13. Hilbertův problém ~ spojitá funkce n proměnných lze vyjádřit pomocí konečného počtu funkcí jediné proměnné a sčítání

■ Příklad: $x \cdot y = \exp(\ln x + \ln y)$

V: Necht' $f: [0, 1]^n \rightarrow [0, 1]$ je spojitá funkce. Potom existují funkce jediné proměnné g a Φ_q , pro $q = 1, \dots, 2n+1$ a konstanty λ_p , pro $p = 1, \dots, n$ takové, že

$$f(x_1, \dots, x_n) = \sum_{q=1}^{2n+1} g\left(\sum_{p=1}^n \lambda_p \Phi_q(x_p)\right)$$

Kolmogorovovy sítě



Aproximace funkcí (1)

- ♦ Libovolnou spojitou funkci lze vyjádřit pomocí sítě s odpovídajícím počtem výpočetních jednotek (× volba vhodné přenosové funkce)
- ♦ Nejlepší možná aproximace dané funkce (× volba vhodného počtu výpočetních jednotek s uvažovanou přenosovou funkcí)

Aproximace funkcí (2)


V: Spojitou reálnou funkci $f: [0, 1] \rightarrow [0, 1]$ lze aproximovat pomocí sítě prahových jednotek tak, že celková aproximační chyba E je menší než libovolné reálné číslo $\varepsilon > 0$:

$$E = \int_0^1 |f(x) - \tilde{f}(x)| dx < \varepsilon$$

kde \tilde{f} označuje funkci realizovanou sítí prahových jednotek.

Aproximace funkcí (3)

Důkaz: Idea ~ aproximace f pomocí φ_N



Aproximace funkcí (4)

Důkaz (pokračování):

- ◆ Rozdělme interval $[0, 1]$ do N stejně velkých podintervalů pomocí bodů $x_0, x_1, \dots, x_N \in [0, 1]$; $x_0 = 0, x_N = 1$

- ◆ Funkci φ_N definujme jako:

$$\varphi_N(x) = \min \{ f(x'); x' \in [x_i, x_{i+1}] \text{ pro } x_i \leq x \leq x_{i+1} \}$$

- ◆ Dále necht' funkce φ_N aproximuje funkci f tak, že aproximační chyba E_N odpovídá:

$$E_N = \int_0^1 | f(x) - \varphi_N(x) | dx$$

Aproximace funkcí (5)

Důkaz (pokračování):

- ♦ Protože $f(x) \geq \varphi_N(x) \quad \forall x \in [0, 1]$, odpovídá

$$E_N = \int_0^1 f(x) dx - \int_0^1 \varphi_N(x) dx$$

~ dolní součet při výpočtu
Riemannova integrálu f

- ♦ Spojité funkce lze integrovat \rightarrow dolní součet konverguje pro $N \rightarrow \infty$ k integrálu f na intervalu $[0, 1]$
- ♦ Platí tedy, že $E_N \rightarrow 0$ pro $N \rightarrow \infty$, a proto pro libovolné reálné $\varepsilon > 0$ existuje M takové, že $E_N < \varepsilon \quad \forall N \geq M$
- ♦ Funkce φ_N je tedy požadovanou aproximací f .


Aproximace funkcí (6)

Důkaz (pokračování):

- ◆ Realizace funkce $\varphi_N(\mathbf{x})$ pomocí sítě prahových jednotek (\sim neuronová síť)
 - Funkce $\varphi_N(\mathbf{x})$ je skoková a v každém z N podintervalů $[0, 1] : [x_0, x_1), [x_1, x_2), \dots, [x_{N-1}, x_N]$ nabývá odpovídající hodnoty $\alpha_0, \dots, \alpha_N$

Aproximace funkcí (7)

Důkaz (pokračování):



Aproximace funkcí (8)

Důkaz (pokračování):

- ◆ Tato síť je schopna realizovat skokovou funkci $\varphi_N(\mathbf{x})$:
 - Jediným vstupem sítě je \mathbf{x}
 - Každá dvojice jednotek s prahem \mathbf{x}_i a \mathbf{x}_{i+1} zaručuje, že jednotka s prahem \mathbf{x}_i bude aktivní pouze pokud $\mathbf{x}_i \leq \mathbf{x} < \mathbf{x}_{i+1}$.
 - Výstupní jednotka sčítá všechny výstupy předchozí vrstvy jednotek a jako výsledek vydá jejich (vážený) součet
 - Jednotka s prahem $\mathbf{x}_N + \delta$, kde δ je malé kladné číslo, slouží k rozpoznání případů $\mathbf{x}_{N-1} \leq \mathbf{x} \leq \mathbf{x}_N$.
- ◆ Tato síť realizuje funkci φ_N , která aproximuje funkci f nanejvýš s požadovanou chybou. ***QED***

Aproximace funkcí (9)

Poznámka:


Věta platí i pro jednotky (\sim neurony) se sigmoidální přenosovou funkcí, kde $f: [0, 1] \rightarrow (0, 1)$

Důkaz:

- ♦ Obor hodnot funkce f je buď omezen na interval $(0, 1)$
- ♦ Funkci f lze aproximovat pomocí sítě

Aproximace funkcí (10)

Důkaz (pokračování):



Aproximace funkcí (11)

Důkaz (pokračování):

- ◆ Přenosová funkce jednotek s prahem x_i je dána pomocí $s_c(x - x_i)$, kde parametr c určuje strmost přenosové funkce

$$s_c(x - x_i) = \frac{1}{1 + e^{-c(x - x_i)}}$$

- ◆ Síť realizuje odhad funkce φ_N s takovou aproximační chybou, která je menší než libovolná požadovaná mez (> 0)
(~ prahové funkce lze pomocí parametrizované sigmoidy aproximovat s libovolnou přesností)

Aproximace funkcí (12)

Důkaz (pokračování):

- ♦ Váhy (synapsí) mezi první vrstvou jednotek a výstupní jednotkou byly nastaveny tak, že sigmoida bude předávat jako výsledek požadované hodnoty a_i
- ♦ Dále je třeba zaručit, že pro každý vstup x bude první vrstva předávat výstupní vrstvě jen jedinou jedničku
→ první vrstva sítě určí, ke kterému z N segmentů x patří

QED


Aproximace funkcí (13)

Vícerozměrný případ:

Sít' pro aproximaci funkce $f: [0,1]^n \rightarrow (0,1)$ lze zkonstruovat na základě předchozích myšlenek:

- nutná rozšíření pro dvourozměrný případ
 - Rozpoznání x -ových i y -ových „intervalů“
 - 2 jednotky vlevo pro $x_0 \leq x < x_I$
 - 2 jednotky vlevo pro $y_0 \leq y < y_I$
 - Jednotka s prahem 1.5 rozpoznává konjunkci obou podmínek (pro x a y)

Aproximace funkcí (14)



- ♦ „Výstup“ má váhu $s_0^{-1}(\alpha_{12})$, takže výstupní jednotka se sigmoidou dává α_{12}

→ toto číslo odpovídá požadované aproximaci funkce f v intervalu: $[x_0, x_1) \times [y_1, y_2)$

NP-úplnost problému učení

Problém splnitelnosti

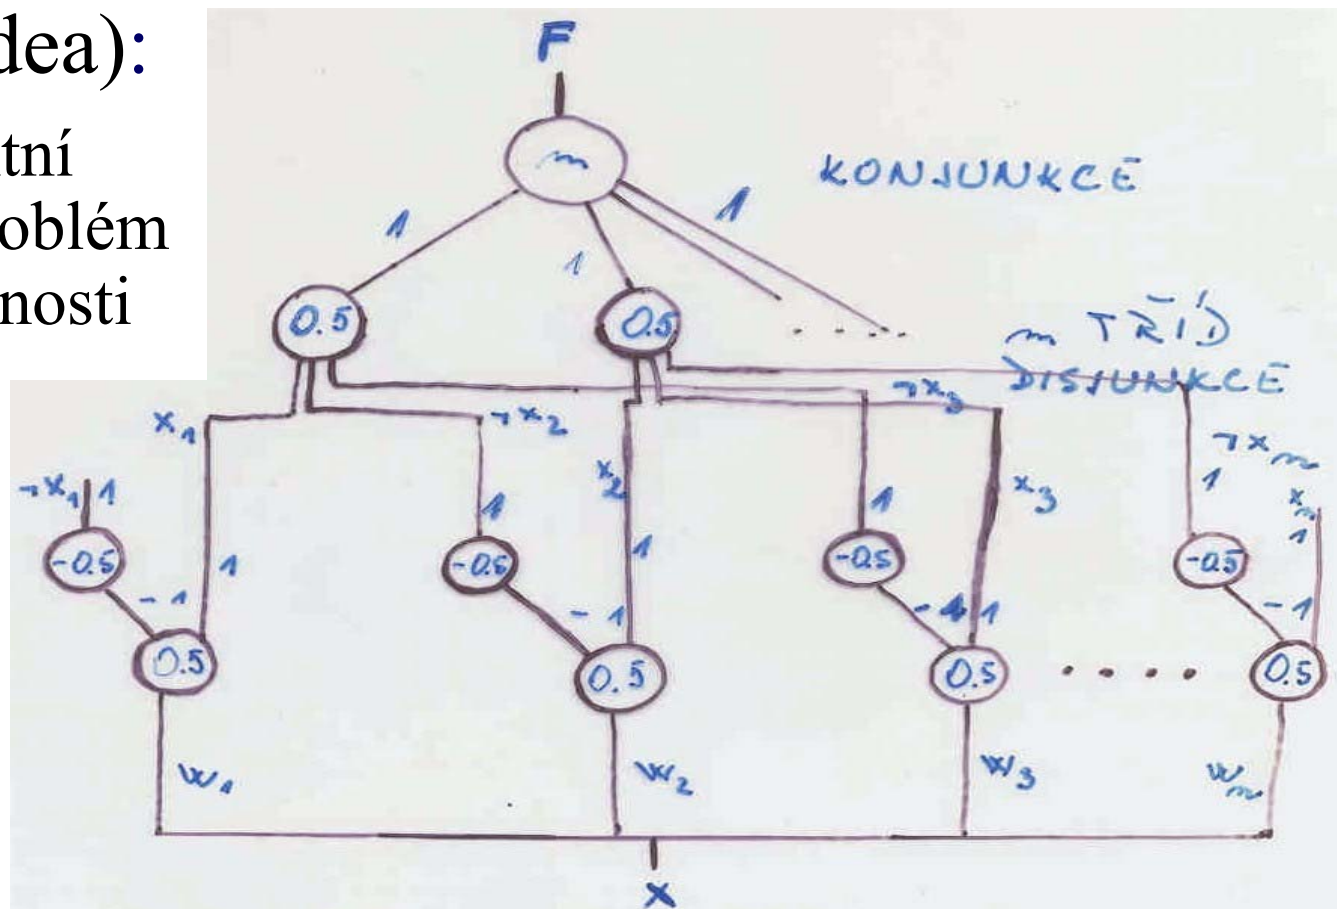
D: Necht' V je množina n logických proměnných a necht' F je logická formule v konjunktivní normální formě, která obsahuje jen proměnné z V . Problém splnitelnosti spočívá v přiřazení pravdivostních hodnot proměnným z V tak, aby měla formule F pravdivostní hodnotu *TRUE*.

V: Obecný problém učení je pro sítě prahových jednotek NP-úplný.

NP-úplnost problému učení (2)

Důkaz (idea):

ekvivalentní
sít' pro problém
3-splnitelnosti



NP-úplnost problému učení (3)

Důkaz (pokračování):

1. 3-splnitelnost logických formulí (3-SAT) lze redukovat (převést) na problém učení neuronových sítí

Logickou formuli F v konjunktivní normální formě, která obsahuje n proměnných, lze v polynomiálním čase převést na síť výše uvedeného typu:

- Každé proměnné x_i je přiřazena váha w_i
- Spoje k výpočetním jednotkám ze třetí vrstvy jsou určeny příslušnou konjunktivní normální formou

NP-úplnost problému učení (4)

Důkaz (pokračování):

- Tyto operace lze provést (při vhodném kódování) v polynomiálním čase, protože pro m různých disjunkcí v 3-SAT-výrazu platí, že $m \leq (2n)^3$
- Jestliže existuje instance A s pravdivostními hodnotami proměnných x_i taková, že F je splněna, potom existují váhy w_1, w_2, \dots, w_n , které řeší problém učení

NP-úplnost problému učení (5)

Důkaz (pokračování):

- Postačí zvolit váhy $w_i = 1$, jestliže $x_i = 1$;
a $w_i = 0$, jestliže $x_i = 0$.
(V obou případech tedy zvolíme $w_i = x_i$.)
- Podobně i opačným způsobem:
jestliže existují váhy w_1, w_2, \dots, w_n , které řeší
problém učení, potom vede instance $x_i = 1$ pro
 $w_i \geq 0.5$ a $x_i = 0$ jinak ke splnění F

NP-úplnost problému učení (6)

Důkaz (pokračování):

2. Dále je třeba ukázat, že problém učení patří do třídy NP (řešení lze ověřit v polynomiálním čase)
 - Jsou-li dány váhy w_1, w_2, \dots, w_n , potom lze po jediném „průchodu sítí“ ověřit, zda je její výstup F roven 1
 - Počet výpočetních kroků přímo závisí na počtu proměnných n a na počtu disjunkcí m (který je omezen polynomem $(2n)^3$)

NP-úplnost problému učení (7)

Důkaz (pokračování):

- Čas potřebný k ověření dané („uhodnuté“) instance je tedy omezen polynomem nad n
- Daný problém učení tedy patří do třídy NP

QED

Poznámka:

Pro některé speciální typy jednoduchých neuronových sítí je problém učení řešitelný v polynomiálním čase (pomocí metod lineárního programování)

Počet oblastí v příznakovém prostoru (1)

- ♦ Kapacita neuronu závisí na dimenzi váhového prostoru a počtu „řezů dělicích nadrovin“

→ **Otázka:**

Kolik oblastí je určeno m dělicími nadrovinami dimenze $n - 1$ v n - rozměrném prostoru?


- přitom budeme uvažovat pouze takové nadroviny, které procházejí počátkem

→ Průnik l nadrovin ; $l \leq n$ bude dimenze $n - l$

Počet oblastí v příznakovém prostoru (2)

- ♦ 2 – rozměrný případ:


m přímek pocházejících počátkem vytváří nanejvýš $2 \cdot m$ navzájem různých oblastí



Počet oblastí v příznakovém prostoru (3)

- ♦ 3 – rozměrný případ:

- každý nový řez zvýší počet oblastí až $2 \times$



- ♦ obecně: n řezů $(n - 1)$ – rozměrnými nadrovinami v n – rozměrném prostoru vytváří nanejvýš 2^n různých oblastí

Počet oblastí v příznakovém prostoru (4)

Věta: Necht' $R(m, n)$ označuje počet oblastí určených m různými dělicími nadrovinami dimenze $n-1$ v n -rozměrném prostoru. Dále necht' $R(1, n) = 2$ pro $n \geq 1$ a $R(m, 0) = 0 \quad \forall m \geq 1$.

Potom pro $n \geq 1$ a $m > 1$:

$$R(m, n) = R(m-1, n) + R(m-1, n-1)$$

Počet oblastí v příznakovém prostoru (5)

Důkaz (indukcí přes m):

1. $m = 2$ a $n = 1$: Platí, protože
$$R(2, 1) = R(1, 1) + R(1, 0) = 2 + 0 = 2$$
2. $m = 2$ a $n \geq 2$: $R(2, n) = 4 \Rightarrow$ platí, protože
$$R(2, n) = R(1, n) + R(1, n-1) = 2 + 2 = 4$$
3. $m + 1$ nadrovin dimenze $n - 1$ v n -rozměrném prostoru ($n \geq 2$) :
 - Prvních m nadrovin určuje $R(m, n)$ oblastí v n -rozměrném prostoru

Počet oblastí v příznakovém prostoru (6)

Důkaz (pokračování):

- $(m + 1)$ - ní nadrovina protíná prvních m nadrovin v m nadrovinách dimenze $n - 2$
- Těchto m nadrovin (dimenze $n - 2$) rozděljuje $(n - 1)$ - rozměrný prostor do $R(m, n - 1)$ oblastí
- Po řezu $(m+1)$ -ní nadrovinou vzniklo $R(m, n - 1)$ nových oblastí

→ Nový počet oblastí je tedy:

$$R(m + 1, n) = R(m, n) + R(m, n - 1)$$

QED

Počet oblastí v příznakovém prostoru (7)

- ♦ Možná alternativa výpočtu podle:

$$R(m, n) = 2 \sum_{i=0}^{n-1} \binom{m-1}{i}$$

- × S rostoucím n roste počet Boolovských funkcí výrazně rychleji než počet různých oblastí vytvořených nadrovinami v obecné poloze
 - tento počet může být obecně větší než počet prahových funkcí nad binárními vstupy

Počet oblastí v příznakovém prostoru (8)

Příklad:

n	POČET BOOLOVSKÝCH FUNKCÍ (2^{2^n})	POČET PRAHOVÝCH FUNKCÍ ($T(2^n, n)$)	POČET OBLASTÍ $R(2^n, n)$
1	4	2	2
2	16	14	14
3	256	104	128
4	65536	1882	3882
5	4.3×10^9	94572	412736

Počet oblastí v příznakovém prostoru (9)

Důsledek:

Problémy s učení ~ je-li počet vstupních vektorů příliš vysoký, nemusí být síť schopna vytvořit s předem daným pevným počtem skrytých neuronů potřebný počet oblastí

- **Zobecňování (generalizace)**
 - ~ očekávaný počet správně klasifikovaných vzorů
- **Přeučení**
 - ~ chybná interpolace vzorů mimo trénovací množinu
- **Vapnik – Chervonenkissova dimenze (VC-dimenze)**
 - ~ konečná VC-dimenze \rightarrow „třidu konceptů“ lze naučit

Vapnik – Chervonenkisova dimenze (VC-dimenze) (1)

D: Necht' $C = \{f_i\}$ je množina funkcí (concept class)
Množinu m trénovacích vzorů $\{t_k\}_{k=1,\dots,m}$ lze
rozčlenit pomocí C , jestliže pro každé ze 2^m
možných označení těchto vzorů $1/0$, existuje
alespoň jedna funkce f_i , která tomuto označení
vyhovuje.

D: VC-dimenze V množiny funkcí C je definována
jako největší m , pro které existuje množina m
rozčlenitelných trénovacích vzorů.

Vapnik – Chervonenkisova dimenze (VC–dimenze) (2)

- ◆ Pokud existuje pro libovolné m množina m trénovacích vzorů, které lze rozčlenit pomocí C , je VC-dimenze C rovna nekonečnu
→ Takový problém je „NENAUČITELNÝ“
- ◆ VC-dimenze množiny funkcí obecně nezávisí na počtu parametrů
- ◆ VC-dimenze je důležitá pro správné zobecňování sítí
 - Sít' může mít mnoho parametrů, ale měla by mít malou VC-dimenzi → lepší generalizace
 - Velká VC-dimenze bývá spojena s horší generalizací

Vapnik – Chervonenkisova dimenze (VC–dimenze) (3)



Příklad:

1. VC-dimenze množiny lineárních indikačních funkcí

$$Q(\vec{z}, \alpha) = \Theta \left\{ \sum_{p=1}^n \alpha_p z_p + \alpha_0 \right\} \quad \text{v } n - \text{rozměrném prostoru}$$

je rovna $n + 1$ (tzn. lze rozčlenit nanejvýš $n + 1$ vzorů)

$n = 2$



Vapnik – Chervonenkisova dimenze (VC–dimenze) (4)

2. VC-dimenze množiny následujících funkcí


$f(z, \alpha) = \theta(\sin \alpha z)$, $\alpha \in \mathbb{R}$ je nekonečná

- Body $z_1 = 10^{-1}, \dots, z_m = 10^{-m}$ lze rozčlenit pomocí funkcí z této množiny
- K rozčlenění těchto vzorů do dvou tříd ($+1 / -1$) daných posloupností $\delta_1, \dots, \delta_m$; $\delta_i \in \{0, 1\}$ stačí zvolit hodnotu parametru

$$\alpha = \pi \left(\sum_{i=1}^m (1 - \delta_i) 10^i + 1 \right)$$


Vapnik – Chervonenkisova dimenze (VC–dimenze) (5)

- při volbě vhodného koeficientu α lze pro libovolný počet m zvolených bodů aproximovat libovolnou funkci omezenou v $< +1 / -1 >$ pomocí $\sin \alpha z$



Vapnik – Chervonenkisova dimenze (VC–dimenze) (6)

Problém „přeučení“ ~ sít' se naučí i „šum“



Vapnik – Chervonenkissova dimenze (VC–dimenze) (7)

- ◆ Pro síť s počtem vah W a počtem neuronů N a s omezením pro generalizační chybu ε , je počet trénovacích vzorů P potřebných pro správné zobecňování: $P \geq (W/\varepsilon) \log_2 (N/\varepsilon)$
- ◆ Vrstevnatá síť s 1 skrytou vrstvou nemůže dobře zobecňovat, jestliže bylo méně než W/ε náhodně vybraných trénovacích vzorů, tj. $P \geq W/\varepsilon$
 - Pro požadovanou přesnost alespoň 90% je třeba vybrat alespoň $10 \cdot W$ vzorů