

# Neuronové sítě

Doc. RNDr. Iveta Mrázová, CSc.

Katedra teoretické informatiky

Matematicko-fyzikální fakulta

Univerzity Karlovy v Praze

# Neuronové sítě

## – Učení bez učitele –

Doc. RNDr. Iveta Mrázová, CSc.

Katedra teoretické informatiky

Matematicko-fyzikální fakulta

Univerzity Karlovy v Praze

# Učení bez učitele

- ◆ Učení bez učitele:

- Samoorganizace a shlukování

- ◆ Motivace:

- Síť sama rozhodne, která odezva je pro daný vzor nejlepší a podle toho nastaví své váhy

- ◆ Problém:

- Určit počet a rozložení shluků v příznakovém prostoru

# Učení bez učitele (2)



NEVĚDĚT, ŽE JE NA NAŠÍ STRANĚ PRAVDA, TAK BYCH SE DOCELA BÁL.

# Učení bez učitele (3)



DÍVČÍ VÁLKA VLASTNĚ NIKDY NEBYLA. ROZMĚLNILA SE IHNEĎ V DROBNÉ ŠARVÁTKY.

# Učení bez učitele (4)

## Kompetiční učení:

- ♦ Boj o „právo reprezentovat předložený vzor“
- ♦ „Potlačování soupeřů“ → **INHIBICE**
- ♦ Pravidlo „vítěz bere vše“  
(WTA – Winner\_takes\_all)


## Posilované učení (reinforcement):

- ♦ Důraz na co nejlepší reprodukci vstupů

# Kompetiční učení bez učitele

- ♦  $n$  – rozměrný vstupní vzor je zpracováván pomocí takového počtu neuronů, který odpovídá (předpokládanému) počtu shluků
- ♦ Neurony v tomto případě počítají (Euklidovskou) **vzdálenost mezi předloženým vzorem a svým váhovým vektorem**

# Kompetiční učení bez učitele (2)



- ♦ V kompetici „vítězí“ neuron, který ke nejblíže předloženému vzoru
- ♦ Vítězný neuron bude nejaktivnější a bude potlačovat – **inhibovat** – aktivitu ostatních neuronů



# Kompetiční učení bez učitele (2a)

- ◆ Inhibice pomocí „laterálních spojů“

==> **laterální inhibice**

- ◆ Pro rozhodnutí, zda bude neuron aktivní nebo ne, je nutná globální informace o stavu všech neuronů v síti
- ◆ Aktivita neuronu signalizuje příslušnost předloženého vstupu ke shluku vektorů reprezentovaných tímto neuronem

# Kompetiční učení bez učitele (3)

- ♦ Vítězný neuron zadaptuje své váhy směrem k předloženému vzoru:

$$\Delta \vec{w} = \alpha \cdot (\vec{x} - \vec{w})$$

plasticita sítě (během učení pomalu klesá)

## Cíl:

- ♦ Umístit neurony do středu shluků vzorů
- ♦ Zachovat již vytvořenou strukturu sítě

# Kompetiční učení bez učitele (4)

## ♦ Urychlení procesu učení:

- Vhodná inicializace vah
- Např. podle náhodně vybraných vzorů

## ♦ Problémy:

- Mrtvé (nevyužité) neurony
  - Mřížka v Kohonenově vrstvě
  - Topologické okolí neuronu
  - Řízená kompetice a mechanismus svědomí

# Kompetiční učení bez učitele (5)

- ♦ Během učení by se měly váhy jednotlivých neuronů nastavit tak, aby odpovídaly „těžišti příslušného shluku“
- ♦ Energetická funkce množiny  $n$ – rozměrných normovaných vstupních vzorů  $X = \{\vec{x}_1, \dots, \vec{x}_m\}; (n \geq 2)$  je pro  $1$  neuron s váhovým vektorem  $\vec{w}$  dána pomocí:

$$E_X(\vec{w}) = \sum_{i=1}^m \|\vec{x}_i - \vec{w}\|^2 ; \quad \vec{w} \in R^n$$

# Kompetiční učení bez učitele (6)

==> lze ukázat, že v optimálním případě je vektor vah umístěn v těžišti shluku vstupních vzorů

$$\begin{aligned} E_X(\vec{w}) &= \sum_{i=1}^m \|\vec{x}_i - \vec{w}\|^2 = \sum_{i=1}^m \sum_{j=1}^n (x_{ij} - w_j)^2 = \\ &= \sum_{i=1}^m \sum_{j=1}^n (x_{ij}^2 - 2x_{ij}w_j + w_j^2) = \\ &= m \left( \sum_{j=1}^n w_j^2 - \frac{2}{m} \sum_{j=1}^n w_j \left( \sum_{i=1}^m x_{ij} \right) \right) + \sum_{i=1}^m \sum_{j=1}^n x_{ij}^2 = \end{aligned}$$

# Kompetiční učení bez učitele (7)

$$\begin{aligned} E_X(\vec{w}) &= m \sum_{j=1}^n \left( w_j^2 - \frac{2}{m} w_j \left( \sum_{i=1}^m x_{ij} \right) + \frac{1}{m^2} \left( \sum_{i=1}^m x_{ij} \right) \left( \sum_{i=1}^m x_{ij} \right) \right) - \\ &\quad - \underbrace{\frac{1}{m} \sum_{j=1}^n \left( \sum_{i=1}^m x_{ij} \right) \left( \sum_{i=1}^m x_{ij} \right) + \sum_{i=1}^m \sum_{j=1}^n x_{ij}^2}_{= K} = \\ &= m \left( \sum_{j=1}^n \left( w_j - \frac{1}{m} \sum_{i=1}^m x_{ij} \right)^2 \right) + K = \\ &= m \left\| \vec{w} - \vec{x}^* \right\|^2 + K \end{aligned}$$

# Kompetiční učení bez učitele (8)

- vektor  $\vec{x}^*$  představuje centroid shluku  $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_m\}$  a  $K$  je konstanta
- energetická funkce má globální minimum v  $\vec{x}^*$

# Kompetiční učení bez učitele (9)

## Klastrovací metody pro empirická vícerozměrná data:

- ♦ dva základní přístupy:
  - $k$  nejbližších sousedů
  - algoritmus  $k$  středů
- ♦  $k$  nejbližších sousedů (učení s učitelem)
  - Vzory z trénovací množiny jsou uloženy a klasifikovány do jedné z  $l$  různých tříd
  - Neznámý vstupní vektor je zařazen do té třídy, ke které patří většina z  $k$  nejbližších vektorů z uložené množiny



# Kompetiční učení bez učitele (10)

- ♦ **algoritmus  $k$  středů ( $k$ -means clustering)**
  - Učení bez učitele
  - Vstupní vektory jsou klasifikovány do  $k$  různých shluků (na začátku učení obsahuje každý shluk právě 1 vektor)
  - Nový vektor  $\vec{x}$  je zařazen k tomu shluku  $k$ , jehož centroid  $\vec{c}_k$  je nejbližší tomuto vzoru

# Kompetiční učení bez učitele (11)

- ♦ **algoritmus  $k$  středů** (pokračování)

- Centroid  $\vec{c}_k$  je pak aktualizován pomocí:

$$\vec{c}_k(new) = \vec{c}_k(old) + \frac{1}{n_k} ( \vec{x} - \vec{c}_k(old) )$$

$n_k$  .... Počet vektorů již přiřazených shluku  $k$

- Tato procedura se iterativně opakuje pro celou množinu dat (jejich strukturu pak vystihují „váhové vektory“  $\vec{c}_i$  ;  $i = 1, \dots, k$  )

→ **Vektorová kvantizace**


# Problém shlukování

- ◆ Dvě množiny vektorů:

- $P$  a  $N$


- ◆ Obtížná „separace“ shluků pomocí jednoduchého perceptronu tak, aby:

$$\vec{w} \cdot \vec{p} \geq 0 \quad \forall \vec{p} \in P \quad \wedge \quad \vec{w} \cdot \vec{n} < 0 \quad \forall \vec{n} \in N$$



# Problém shlukování (2)

- ♦ Tři váhové vektory pro tři shluky



- ♦ Tři různé vektory  $\vec{w}_1$ ,  $\vec{w}_2$  a  $\vec{w}_3$  mohou sloužit jako „reprezentanti“ v jednotlivých shlucích **A**, **B** a **C**

# Problém shlukování (3)

- ♦ Každý z těchto tří vektorů je „relativně blízko“ ke každému vektoru z příslušného shluku
- ♦ Každý váhový vektor odpovídá jednomu bezprahovému neuronu, který je aktivní pouze v případě, že je vstupní vektor dostatečně blízko tomuto váhovému vektoru

**==> Jak určit počet a rozložení shluků?**

# Kompetiční učení - algoritmus

- ♦ Necht'  $X = \{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_l\}$  je množina normovaných vstupních vektorů v  $n$  – rozměrném prostoru, které chceme zařadit do  $k$  různých shluků
- ♦ Neuronová síť se skládá z  $k$  neuronů, z nichž každý má  $n$  vstupů a nulový práh

## Inicializace:

- ♦ Normované váhové vektory  $\vec{w}_1, \dots, \vec{w}_k$  jsou generovány náhodně

# Kompetiční učení – algoritmus (2)

## Test:

- ♦ Náhodně vyber vektor  $\vec{x}_j \in X$
- ♦ Spočítej  $\vec{w}_i \cdot \vec{x}_j$  pro  $i = 1, \dots, k$
- ♦ Vyber  $\vec{w}_m$  takový, že  $\vec{w}_m \cdot \vec{x}_j \geq \vec{w}_i \cdot \vec{x}_j \quad (\forall i = 1, \dots, k)$
- ♦ Proved' Aktualizaci

## Aktualizace:

- ♦ Nahrad'  $\vec{w}_m(new)$  vektorem  $\vec{w}_m(old) + \vec{x}_j$  a znormuj
- ♦ Pokračuj v Testu

# Kompetiční učení – algoritmus (3)

- ♦ Po provedení předem určeného počtu kroků lze algoritmus ukončit
- ♦ Váhové vektory  $k$  neuronů jsou „přitahovány“ směrem k centru jednotlivých shluků ve vstupním prostoru
- ♦ Algoritmus je založen na principu „**vítěz bere vše**“ ( $\sim$  WINNER-TAKES-ALL)



# Kompetiční učení – algoritmus (4)

- ◆ Použití normovaných vektorů zabraňuje tomu, aby byl některý z váhových vektorů příliš velký, takže by „vyhrával“ kompetici příliš často
  - Ostatní neurony by se pak nikdy neaktualizovaly a zůstaly by nevyužité → **„mrtvé neurony“**
- ◆ Protože jsou vstupní i váhové vektory normované, je skalární součin  $\vec{w}_i \cdot \vec{x}_j$  váhového a vstupního vektoru roven kosinu úhlu mezi těmito dvěma vektory

# Kompetiční učení – algoritmus (5)

- ♦ Algoritmus učení zaručuje, že bude aktualizován ten vektor  $\vec{w}_m$ , který leží nejbliž k předloženému vstupnímu vzoru
- ♦ Při aktualizaci je váhový vektor  $\vec{w}_m$  otočen směrem k  $\vec{x}_j$

## Různá pravidla učení:

- ♦ Aktualizace pomocí parametru učení

$$\Delta \vec{w}_m = \eta \vec{x}_j \quad ; \quad \eta \in (0,1) \text{ pomalu klesá v čase}$$

→ **plasticita sítě**

# Kompetiční učení – algoritmus (6)

## Různá pravidla učení (pokračování):

### ♦ Diferenční aktualizace

$$\Delta \vec{w}_m = \eta (\vec{x}_j - \vec{w}_m)$$

- „oprava“ odpovídá rozdílu mezi oběma vektory


### ♦ Dávková aktualizace

- „korekce“ vah pro jednotlivé vzory se kumuluje
- Váhy se změň po několika iteracích nejednou  
→ stabilnější proces učení

# Kompetiční učení – algoritmus (7)

## Stabilita řešení

- ♦ Nutnost vhodné míry pro „dobré shlukování“
  - **nejjednodušší řešení:** určit vzdálenost mezi shluky
- ♦ Dva shluky vektorů a dva vektory „representativních vah“:
  - Oba vektory „representantů“ leží blízko vektorů, které leží v jejich odpovídajícím shluku




# Kompetiční učení – algoritmus (8)

## Stabilita řešení (pokračování):

- $\vec{w}_1$  leží uvnitř „svazku“ definovaného vektory svého shluku
- $\vec{w}_2$  leží vně „svazku“ příslušejícího  $\vec{w}_1$
- Vektor  $\vec{w}_1$  v dalších iteracích už „neopustí“ svůj „svazek“
- Vektor  $\vec{w}_2$  se v některé z dalších iterací dostane do svého svazku a dál v něm už zůstane

→ takové řešení bude stabilní



# Kompetiční učení – algoritmus (9)

## Řešení ve stabilním rovnovážném stavu:

- ♦ **Intuitivní představa:**
  - **stabilní rovnovážný stav vyžaduje jasně ohraničené shluky**
- ♦ **Pokud se jednotlivé shluky navzájem překrývají nebo jsou příliš rozsáhlé, nemusí být stabilní řešení nalezeno**  
**=> nestabilní rovnovážný stav**

# Stabilita řešení - analýza

## Definice:

Nechť  $P$  je množina  $\{\vec{p}_1, \dots, \vec{p}_m\}$   $n$  – rozměrných ( $n \geq 2$ ) vektorů ležících ve stejném poloprostoru ( $\sim$  formální omezení velikosti shluku).

Svazek  $K$  definovaný pomocí  $P$  je množina všech vektorů  $\vec{x}$  tvaru  $\vec{x} = \alpha_1 \vec{p}_1 + \dots + \alpha_m \vec{p}_m$ , kde  $\alpha_1, \dots, \alpha_m$  jsou kladná reálná čísla.

- ♦ Svazek shluku obsahuje všechny vektory „uvnitř“ shluku
- ♦ Průměr svazku definovaného normovanými vektory odpovídá největšímu možnému úhlu mezi vektory ve shluku

# Stabilita řešení – analýza (2)

## Definice:

(Úhlový) průměr  $\varphi$  svazku  $K$  definovaného normovanými vektory  $\{\vec{p}_1, \dots, \vec{p}_m\}$  odpovídá:

$$\varphi = \sup \left\{ \arccos(\vec{a} \cdot \vec{b}) \mid \forall \vec{a}, \vec{b} \in K ; \|\vec{a}\| = \|\vec{b}\| = 1 \right\}$$

kde  $0 \leq \arccos(\vec{a} \cdot \vec{b}) \leq \pi$

- ♦ Postačující podmínkou pro stabilní řešení je, aby byl úhlový průměr svazků menší než jejich vzájemná vzdálenost



# Stabilita řešení – analýza (3)

## Definice:

Nechť  $P = \{\vec{p}_1, \dots, \vec{p}_m\}$  a  $N = \{\vec{n}_1, \dots, \vec{n}_k\}$  jsou dvě neprázdné množiny normovaných vektorů v  $n$ -rozměrném prostoru ( $n \geq 2$ ), které definují svazky  $K_P$  a  $K_N$

- Jestliže je průnik těchto dvou svazků prázdný, je (úhlová) vzdálenost mezi  $K_N$  a  $K_P$  dána pomocí:

$$\psi = \inf \left\{ \arccos(\vec{p} \cdot \vec{n}); \vec{p} \in K_P, \vec{n} \in K_N \text{ a } \|\vec{p}\| = \|\vec{n}\| = 1 \right\}$$

$$\text{kde } 0 \leq \arccos(\vec{p} \cdot \vec{n}) \leq \pi$$

- Jestliže se  $K_P$  a  $K_N$  prolínají, je  $\psi_{P,N} = 0$

# Stabilita řešení – analýza (4)

- ◆ Jestliže je úhlová vzdálenost mezi shluky větší než úhlový průměr svazků, potom existuje stabilní řešení
  - Váhové vektory budou ležet ve svazku jim příslušejícího shluku
  - Jestliže se váhový vektor už „dostal“ dovnitř příslušného svazku, zůstane tam i nadále

## Kontrola kvality shlukování:

- ◆ Výhodnější je menší počet „kompaktnějších“ shluků
- ◆ Ohodnocovací funkce pro penalizaci příliš vysokého počtu shluků

# PCA – Principal Component Analysis

~ redukce dimenzionality vstupních dat

→ použít méně příznaků bez ztráty podstatné informace

→ výběr nejdůležitějších příznaků


~ dána množina  $m \times n$  – rozměrných vektorů:

$$\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_m\}$$

~ prvním „nejdůležitějším“ příznakem pro tuto množinu vektorů je vektor  $\vec{w}$ , který maximalizuje výraz


$$\frac{1}{m} \sum_{i=1}^m \|\vec{w} \cdot \vec{x}_i\|^2$$

# PCA – Principal Component Analysis (2)



- ◆ Rozložení vstupních dat:
  - 1. PC: největší rozptyl
  - 2. PC: kolmá k 1. PC a největší rozptyl  
(~ odečíst od  $\vec{x}$  jeho ortogonální projekci na 1. PC)

# PCA – Principal Component Analysis (3)



## ◆ Použitý model:

- Lineární asociátor
  - jako výsledek počítá pouze vážený součet vstupů
- Posilované učení – Ojův algoritmus učení

# Výpočet nejdůležitějších příznaků pomocí umělých neuronových sítí

**Ojův algoritmus učení** (E. Oja, 1982)  
(pro výpočet prvního nejdůležitějšího příznaku)

## Předpoklad:

- Těžiště vstupních dat je vycentrováno v počátku

## Start:

- Necht'  $X$  je množina  $n$  – rozměrných vektorů
- Vektor  $\vec{w}$  je inicializován náhodně (  $\vec{w} \neq 0$  )
- Je zvolen parametr učení  $\gamma$  (  $0 < \gamma \leq 1$  )

# Výpočet nejdůležitějších příznaků pomocí umělých neuronových sítí (2)

## Ojův algoritmus učení (pokračování):

### Adaptace:

- z množiny  $X$  je náhodně vybrán vektor  $\vec{x}$
- Spočítá se skalární součin  $\Phi = \vec{x} \cdot \vec{w}$
- Nový váhový vektor je  $\vec{w} + \gamma \Phi (\vec{x} - \Phi \vec{w})$
- Zmenši  $\gamma$  a přejdi k „Adaptaci“

### Podmínka pro ukončení adaptace

- např. počet provedených iterací

# Výpočet nejdůležitějších příznaků pomocí umělých neuronových sítí (3)

## ♦ Parametr učení $\gamma$

- Parametr učení je třeba zvolit dostatečně malý, aby byla zaručena adekvátní adaptace vah (omezení velkých oscilací)

## ♦ „Automatická normalizace“ váhového vektoru

- Odpadá nutnost znát globální informaci o všech vzorech
- Postačí lokální informace o aktualizované váze, vstupu a skalárním součinu asociátoru

## ♦ První nejdůležitější příznak odpovídá směru nejdelšího vlastního vektoru korelační matice uvažovaných vstupních vektorů




# Konvergence Ojova algoritmu učení

**Pokud existuje jednoznačné řešení, bude Ojův algoritmus učení konvergovat:**

Idea důkazu:

Adaptace  $\vec{w}$  směrem k  $\vec{x}$



- ) začne-li Ojův algoritmus učení s váhovým vektorem uvnitř svazku, bude v něm oscilovat, ale neopustí ho
- ) pro  $\|\vec{w}\| = 1$  odpovídá skalární součin  $\Phi = \vec{x} \cdot \vec{w}$  délce projekce  $\vec{x}$  na  $\vec{w}$

# Konvergence Ojova algoritmu učení (2)

## Idea důkazu (pokračování):

- ) vektor  $\vec{x} - \Phi \vec{w}$  je kolmý na  $\vec{w}$
- ) iterace Ojova algoritmu učení přitahují  $\vec{w}$  k vektorům ze shluku  $X$
- ) pokud zůstane délka  $\vec{w}$  rovna  $1$  (anebo blízko  $1$ ), umístí se  $\vec{w}$  v procesu učení v centru shluku
- ) dále je ještě třeba ukázat, že vektor  $\vec{w}$  je Ojovým algoritmem automaticky normován:  
Idea: a) délka vektoru  $\vec{w}$  je větší než  $1$   
b) délka vektoru  $\vec{w}$  je menší než  $1$


# Konvergence Ojova algoritmu učení (3)

a) délka vektoru  $\vec{w}$  je větší než **1**

- Délka vektoru  $(\vec{x} \cdot \vec{w})\vec{w}$  je větší než délka ortogonální projekce  $\vec{x}$  na  $\vec{w}$
- Dále předpokládejme, že  $\vec{x} \cdot \vec{w} > 0$ , tj. že vektory  $\vec{x}$  a  $\vec{w}$  nejsou navzájem příliš vzdálené
- Vektor  $\vec{x} - (\vec{x} \cdot \vec{w})\vec{w}$  má zápornou projekci na  $\vec{w}$ ,


protože

$$\begin{aligned} & (\vec{x} - (\vec{x} \cdot \vec{w})\vec{w}) \cdot \vec{w} = \\ & = \vec{x} \cdot \vec{w} - \|\vec{w}\|^2 \vec{x} \cdot \vec{w} < 0 \end{aligned}$$



# Konvergence Ojova algoritmu učení (4)

- Výsledek po větším počtu iterací:
  - (vektor  $\vec{x} - (\vec{x} \cdot \vec{w})\vec{w}$  má jednu složku kolmou na  $\vec{w}$  a druhou složku, která směřuje opačným směrem než  $\vec{w}$  )
  - $\vec{w}$  přejde do centra shluku vektorů (kolmá složka v průměru vymizí)
  - $\vec{w}$  se bude s rostoucím počtem iterací tohoto typu zmenšovat (!pozor na nebezpečí změny orientace  $\vec{w}$  v jedné iteraci)



# Konvergence Ojova algoritmu učení (5)

- Vhodná volba parametru učení  $\gamma$  a normalizace vektorů z trénovací množiny před začátkem učení:**

- jestliže má vektor  $\vec{x}$  pozitivní skalární součin  $\Phi$  s  $\vec{w}$ , měl by mít i nový váhový vektor pozitivní skalární součin s  $\vec{x}$ :
- mělo by tedy platit:  $\vec{x} \cdot (\vec{w} + \gamma \Phi (\vec{x} - \Phi \vec{w})) > 0$

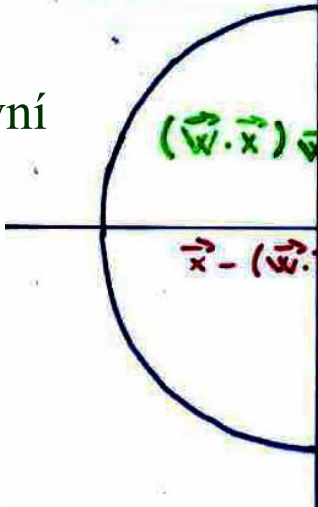
$$\Phi + \gamma \Phi \|\vec{x}\|^2 - \gamma \Phi \Phi^2 > 0$$


$$\Phi \left( 1 + \gamma \left( \|\vec{x}\|^2 - \Phi^2 \right) \right) > 0$$

$$> 0 \Rightarrow \gamma \left( \|\vec{x}\|^2 - \Phi^2 \right) > -1$$

- Pro dostatečně malé kladné  $\gamma$  platí vždy

# Konvergence Ojova algoritmu učení (6)

- a) délka vektoru  $\vec{w}$  je menší než 1  
(analogicky k a) )
- vektor  $\vec{x} - (\vec{x} \cdot \vec{w})\vec{w}$  má pozitivní projekci na  $\vec{w}$
  - zvětšování  $\vec{w}$
- ❑ Kombinace a) a b)  $\Rightarrow \vec{w}$  se dostane do centra shluku a délka bude oscilovat kolem 1 (pro dostatečně malé  $\gamma$ )
- ❑ problémy:  
„řídke“ shluky
- 



# Ojův algoritmus učení: problémy a zobecnění

Problémy: -) „řidké“ shluky  
-) příliš velké rozdíly v délce vstupních vektorů

Výpočet většího počtu  
nejdůležitějších příznaků:

