

# Teorie užitku

- Většinou měříme výplatu, hodnotu atd. penězi.
- MEU (maximalizace očekávaného zisku) je většinou rozumná věc k volbě.
- Ale občas je lidská intuice jiná a je na nás, jestli věříme víc intuici nebo tomu, že máme maximalizovat aditivní MEU.

# Loterie

Mějme generátor náhodného výsledku podle zadané pravděpodobnosti. Můžete se účastnit jedné ze dvou loterií, otázka zní, kterou si vyberete.

**Odpovídejte na základě intuice**, pak teprve max. MEU.

## Loterie A

- ① 80% šance vyhrát \$400
- ② 100% šance vyhrát \$300

Co zvolíte?

## Loterie B

A z této dvojice?

- ① 20% šance vyhrát \$400
- ② 25% šance vyhrát \$300

Co zvolíte?

# Loterie

Mějme generátor náhodného výsledku podle zadané pravděpodobnosti. Můžete se účastnit jedné ze dvou loterií, otázka zní, kterou si vyberete.

**Odpovídejte na základě intuice**, pak teprve max. MEU.

## Loterie A

- ① 80% šance vyhrát \$400
- ② 100% šance vyhrát \$300

Co zvolíte?

## Loterie B

A z této dvojice?

- ① 20% šance vyhrát \$400
- ② 25% šance vyhrát \$300

Co zvolíte?

# Užitek peněz

## Loterie

Opět výběr ze dvou loterií:

- Buď dostat \$1000000
- nebo hodit korunou a na 50% dostat \$3000000

## Užitek peněz

- Ekonomové říkají, že užitek peněz není lineární.
- Nechť mám v tuto chvíli  $k$  peněz. Užitek mít o  $n$  víc je zhruba (v dolarech):

$$U(S_{k+n}) = -263.31 + 22.09 \log(n + 150000)$$

v rozmezí  $-\$150000$  a  $\$800000$ . (Mr. Beard)

# Užitek peněz

## Loterie

Opět výběr ze dvou loterií:

- Buď dostat \$1000000
- nebo hodit korunou a na 50% dostat \$3000000

## Užitek peněz


- Ekonomové říkají, že **užitek peněz není lineární.**
- Nechť mám v tuto chvíli  $k$  peněz. Užitek mít o  $n$  víc je zhruba (v dolarech):

$$U(S_{k+n}) = -263.31 + 22.09 \log(n + 150000)$$

v rozmezí  $-\$150000$  a  $\$800000$ . (Mr. Beard)

## Příklad - Mléko

Nadojené mléko: Při uvedených cenách: použít, vyhodit, testovat?



	$Inf=y$	$Inf=n$
$Pour?=y$	0	100
$Pour?=n$	98	98

# Očekávaný zisk (expected utility, value)

I když známe zisk  $V(d, x, e)$  v každé možné situaci  $d, x, e$ , nemáme jistotu, která situace nastane. Proto nemůžeme maximalizovat  $V(d, x, e)$ , ale maximalizujeme očekávaný zisk:

$$EU(d|e) = \sum_x V(d, x, e) \cdot P(X|d, e)$$

Pokud máme více funkcí užitku  $V_1, \dots, V_n$ , pak (téměř vždy) uvažujeme aditivní skládání, tj.  $V(U) = V_1(U) + \dots + V_n(U)$ .

Jednotlivé funkce  $V_i(U)$  mohou záviset na různých podmnožinách prostoru náhodných veličin  $U$ .

# (Pravděpodobnostní) rozhodovací stromy

- Rozhodovací strom obsahuje tři typy uzlů:
  - rozhodnutí  $D_i$
  - náhodné uzly  $X_i$
  - listy; listům je přiřazen zisk v příslušné situaci definované cestou od kořene.
- pro každou možnou hodnotu rozhodnutí  $D$  a náhodné veličiny  $X$  vychází z uzlu  $D$  resp.  $X$  jedna hrana označená tímto výsledkem  $d_j, x_j$
- větve z náhodné veličiny  $X$  navíc označíme pravděpodobností, s jakou větev zvolíme, za podmínky, že se do uzlu  $X$  dostaneme, tj.  
 $P(X = x_j | \text{cesta z kořene do } X)$ .
- na cestě od kořene do listu se každé rozhodnutí a náhodná veličina vyskytuje nejvýše jednou (nemusí se vyskytovat, pokud neovlivňuje užitek ani pravděpodobnost dosažení listu),
- cesta odpovídá časovému uspořádání: náhodná veličina je před rozhodnutím právě když je hodnota této veličiny známa před rozhodnutím.



# (Pravděpodobnostní) rozhodovací stromy

- Rozhodovací strom obsahuje tři typy uzlů:
  - rozhodnutí  $D_i$
  - náhodné uzly  $X_j$
  - listy; listům je přiřazen zisk v příslušné situaci definované cestou od kořene.
- pro každou možnou hodnotu rozhodnutí  $D$  a náhodné veličiny  $X$  vychází z uzlu  $D$  resp.  $X$  jedna hrana označená tímto výsledkem  $d_j, x_j$
- větve z náhodné veličiny  $X$  navíc označíme pravděpodobností, s jakou větev zvolíme, za podmínky, že se do uzlu  $X$  dostaneme, tj.  
 $P(X = x_j | \text{cesta z kořene do } X)$ .
- na cestě od kořene do listu se každé rozhodnutí a náhodná veličina vyskytuje nejvýše jednou (nemusí se vyskytovat, pokud neovlivňuje užitek ani pravděpodobnost dosažení listu),
- **cesta odpovídá časovému uspořádání:** náhodná veličina je před rozhodnutím právě když je hodnota této veličiny známa před rozhodnutím.

# (Pravděpodobnostní) rozhodovací stromy

- Rozhodovací strom obsahuje tři typy uzlů:
  - rozhodnutí  $D_i$
  - náhodné uzly  $X_j$
  - listy; listům je přiřazen zisk v příslušné situaci definované cestou od kořene.
- pro každou možnou hodnotu rozhodnutí  $D$  a náhodné veličiny  $X$  vychází z uzlu  $D$  resp.  $X$  jedna hrana označená tímto výsledkem  $d_j, x_j$
- větve z náhodné veličiny  $X$  navíc označíme pravděpodobností, s jakou větev zvolíme, za podmínky, že se do uzlu  $X$  dostaneme, tj.  
 $P(X = x_j | \text{cesta z kořene do } X)$ .
- na cestě od kořene do listu se každé rozhodnutí a náhodná veličina vyskytuje nejvýše jednou (nemusí se vyskytovat, pokud neovlivňuje užitek ani pravděpodobnost dosažení listu),
- **cesta odpovídá časovému uspořádání:** náhodná veličina je před rozhodnutím právě když je hodnota této veličiny známa před rozhodnutím.

# (Pravděpodobnostní) rozhodovací stromy


- Rozhodovací strom obsahuje tři typy uzlů:
  - rozhodnutí  $D_i$
  - náhodné uzly  $X_j$
  - listy; listům je přiřazen zisk v příslušné situaci definované cestou od kořene.
- pro každou možnou hodnotu rozhodnutí  $D$  a náhodné veličiny  $X$  vychází z uzlu  $D$  resp.  $X$  jedna hrana označená tímto výsledkem  $d_j, x_j$
- větve z náhodné veličiny  $X$  navíc označíme pravděpodobností, s jakou větev zvolíme, za podmínky, že se do uzlu  $X$  dostaneme, tj.  
 $P(X = x_j | \text{cesta z kořene do } X)$ .
- na cestě od kořene do listu se každé rozhodnutí a náhodná veličina vyskytuje nejvýše jednou (nemusí se vyskytovat, pokud neovlivňuje užitek ani pravděpodobnost dosažení listu),
- **cesta odpovídá časovému uspořádání:** náhodná veličina je před rozhodnutím právě když je hodnota této veličiny známa před rozhodnutím.

# (Pravděpodobnostní) rozhodovací stromy

- Rozhodovací strom obsahuje tři typy uzlů:
  - rozhodnutí  $D_i$
  - náhodné uzly  $X_j$
  - listy; listům je přiřazen zisk v příslušné situaci definované cestou od kořene.
- pro každou možnou hodnotu rozhodnutí  $D$  a náhodné veličiny  $X$  vychází z uzlu  $D$  resp.  $X$  jedna hrana označená tímto výsledkem  $d_j, x_j$
- větve z náhodné veličiny  $X$  navíc označíme pravděpodobností, s jakou větev zvolíme, za podmínky, že se do uzlu  $X$  dostaneme, tj.  
 $P(X = x_j | \text{cesta z kořene do } X)$ .
- na cestě od kořene do listu se každé rozhodnutí a náhodná veličina vyskytuje nejvýše jednou (nemusí se vyskytovat, pokud neovlivňuje užitek ani pravděpodobnost dosažení listu),
- **cesta odpovídá časovému uspořádání:** náhodná veličina je před rozhodnutím právě když je hodnota této veličiny známa před rozhodnutím.

## Příklad - Mléko

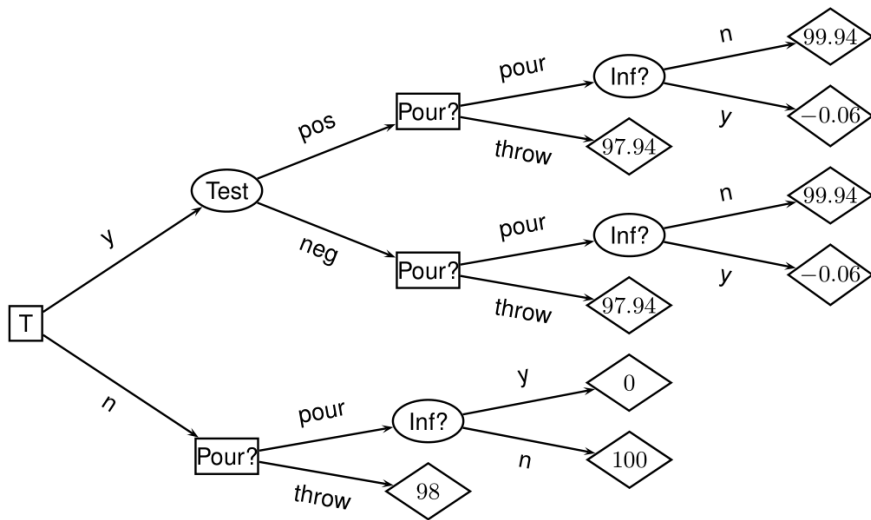
Nadojené mléko: Při uvedených cenách: použít, vyhodit, testovat?



	$Inf=y$	$Inf=n$
$Pour?=y$	0	100
$Pour?=n$	98	98

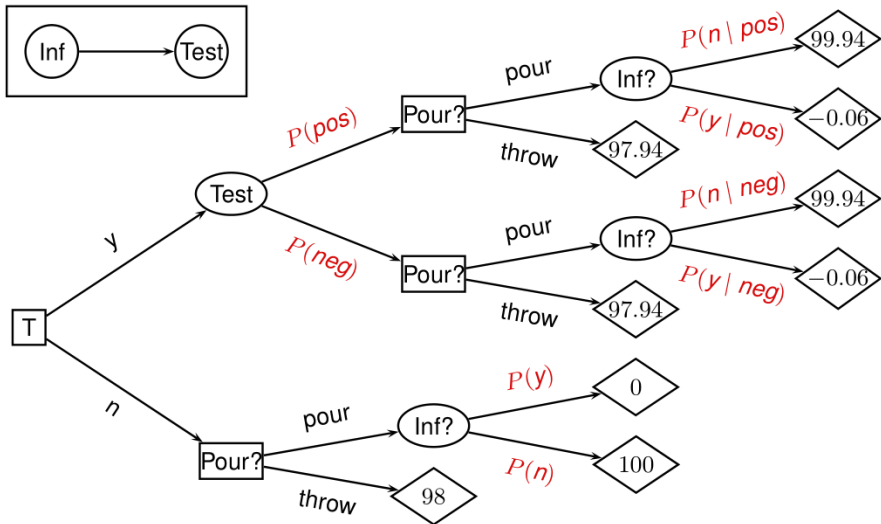
# Příklad - Mléko

Nadojené mléko: použít, vyhodit, testovat?



# Příklad - Mléko

Pravděpodobnostní model + ceny (užitek).

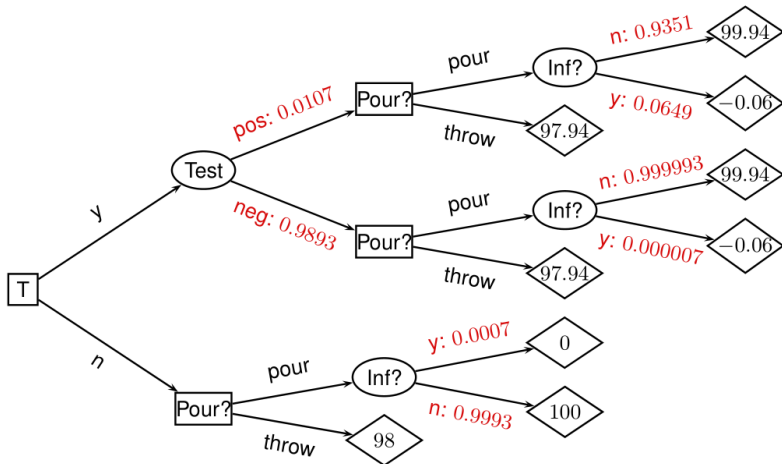


## Příklad - Mléko

Dopočteme pravděpodobnosti.

```
inf <- ctable(~inf, values=c(0.0007,0.9993),levels=c('yes','no'))
```

```
test <- ctable(~test+inf, values=c(1,99,99,1),levels=c('pos','neg'))
```



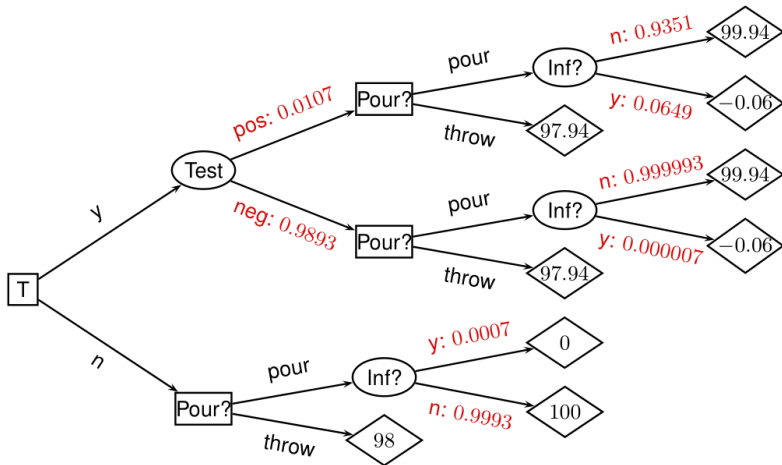


## Příklad - Mléko

Vyhodnotíme. Vážený součet v náhodných uzlech, maximum v rozhodnutích.

$$EU(dole) = 0 \cdot P(y) + 100 \cdot P(n) = 99.93,$$

$$EU(nahore) = 97.94 \cdot P(pos) + 99.94 \cdot P(n, neg) - 0.06 \cdot P(y, neg) = 99.92.$$



# Vyhodnocení rozhodovacího stromu

- Vyhodnocení začínáme od listů, kde je znám zisk  $EU(list) = V(list)$ .
- Jsou-li všechny děti uzlu vyhodnoceny, vyhodnotíme uzel:
  - v rozhodovacím uzlu vybereme dítě s nejvyšším ziskem a opišeme jeho hodnotu; větev označíme.
  - v náhodném uzlu spočteme  $EU(X|cesta) = \sum_{dítě} EU(dítě|cesta) \cdot P(dítě|cesta)$ .
  - v kořeni nám vyjde očekávaný zisk optimální strategie.

## Definition

**Strategie** řešení rozhodování za nejistoty je předpis (např. rozhodovací strom) jaké rozhodnutí zvolit za každé možné situace předchozích rozhodnutí a pozorovaných náhodných veličin.

**Optimální strategie** je strategie s maximálním očekávaným ziskem ze všech strategií pro daný problém.

# Influenční diagram (Influence diagram, Decision graph)

**Influenční diagram** je DAG (orientovaný graf bez cyklů) se třemi typy uzlů a dvěma typy tabulek:

- Rozhodovací a náhodné uzly mají konečné množiny vzájemně se vylučujících stavů, uzly užitku nemají žádné stavy.
- Obdélníkové **rozhodovací uzly** nemají přiřazenou tabulku, resp. tabulku podkladů pro rozhodnutí vypočteme
- Elipsové **náhodné uzly** mají přiřazenou podmíněnou pravděpodobnost stavu pro možné konfigurace rodičů, stejně jak bylo v bayes. síti
- Kosočtvercové **uzly užitku**, (**utility**) mají přiřazenu výplatu (reálné číslo) pro každou konfiguraci rodičů.
- Hrany do náhodných veličin mají závislostní význam, jako v BN.
- Hrany do rozhodovacích uzlů z náhodných veličin mají význam informační:
- Předpokládáme **nezapomínání** – pokud předchozí rozhodnutí znalo veličinu A, pak ji zná i následné rozhodnutí.
- Influenční diagram vyžaduje orientovanou cestu přes všechna rozhodnutí, tj. časové uspořádání na rozhodnutích. (Nevadí, když jsou na cestě i náhodné uzly).

# Influenční diagram (Influence diagram, Decision graph)

**Influenční diagram** je DAG (orientovaný graf bez cyklů) se třemi typy uzlů a dvěma typy tabulek:

- Rozhodovací a náhodné uzly mají konečné množiny vzájemně se vylučujících stavů, uzly užitku nemají žádné stavy.
- Obdélníkové **rozhodovací uzly** nemají přiřazenou tabulku, resp. **tabulku podkladů pro rozhodnutí vypočteme**
- Elipsové **náhodné uzly** mají přiřazeny podmíněnou pravděpodobnost stavu pro možné konfigurace rodičů, stejně jak bylo v bayes. síti
- Kosočtvercové **uzly užitku**, (**utility**) mají přiřazenu výplatu (reálné číslo) pro každou konfiguraci rodičů.
- Hrany do náhodných veličin mají závislostní význam, jako v BN.
- **Hrany do rozhodovacích uzlů z náhodných veličin mají význam informační:**
- Předpokládáme **nezapomínání** – pokud předchozí rozhodnutí znalo veličinu A, pak ji zná i následné rozhodnutí.
- **Influenční diagram vyžaduje orientovanou cestu přes všechna rozhodnutí**, tj. časové uspořádání na rozhodnutích. (Nevadí, když jsou na cestě i náhodné uzly)

# Influenční diagram (Influence diagram, Decision graph)

**Influenční diagram** je DAG (orientovaný graf bez cyklů) se třemi typy uzlů a dvěma typy tabulek:

- Rozhodovací a náhodné uzly mají konečné množiny vzájemně se vylučujících stavů, uzly užitku nemají žádné stavy.
- Obdélníkové **rozhodovací uzly** nemají přiřazenou tabulku, resp. tabulku podkladů pro rozhodnutí vypočteme
- Elipsové **náhodné uzly** mají přiřazenou podmíněnou pravděpodobnost stavu pro možné konfigurace rodičů, stejně jak bylo v bayes. síti
- Kosočtvercové **uzly užitku**, (*utility*) mají přiřazenu výplatu (reálné číslo) pro každou konfiguraci rodičů.
- Hrany do náhodných veličin mají závislostní význam, jako v BN.
- Hrany do rozhodovacích uzlů z náhodných veličin mají význam informační:
- Předpokládáme **nezapomínání** – pokud předchozí rozhodnutí znalo veličinu A, pak ji zná i následné rozhodnutí.
- Influenční diagram vyžaduje orientovanou cestu přes všechna rozhodnutí, tj. časové uspořádání na rozhodnutích. (Nevadí, když jsou na cestě i náhodné uzly)

# Influenční diagram (Influence diagram, Decision graph)

**Influenční diagram** je DAG (orientovaný graf bez cyklů) se třemi typy uzlů a dvěma typy tabulek:

- Rozhodovací a náhodné uzly mají konečné množiny vzájemně se vylučujících stavů, uzly užitku nemají žádné stavy.
- Obdélníkové **rozhodovací uzly** nemají přiřazenou tabulku, resp. tabulku podkladů pro rozhodnutí vypočteme
- Elipsové **náhodné uzly** mají přiřazenou podmíněnou pravděpodobnost stavu pro možné konfigurace rodičů, stejně jak bylo v bayes. síti
- **Kosočtvercové uzly užitku, (utility)** mají přiřazenu výplatu (reálné číslo) pro každou konfiguraci rodičů.
- Hrany do náhodných veličin mají závislostní význam, jako v BN.
- Hrany do rozhodovacích uzlů z náhodných veličin mají význam informační:
- Předpokládáme **nezapomínání** – pokud předchozí rozhodnutí znalo veličinu A, pak ji zná i následné rozhodnutí.
- Influenční diagram vyžaduje orientovanou cestu přes všechna rozhodnutí, tj. časové uspořádání na rozhodnutích. (Nevadí, když jsou na cestě i náhodné uzly)

# Influenční diagram (Influence diagram, Decision graph)

**Influenční diagram** je DAG (orientovaný graf bez cyklů) se třemi typy uzlů a dvěma typy tabulek:

- Rozhodovací a náhodné uzly mají konečné množiny vzájemně se vylučujících stavů, uzly užitku nemají žádné stavy.
- Obdélníkové **rozhodovací uzly** nemají přiřazenou tabulku, resp. tabulku podkladů pro rozhodnutí vypočteme
- Elipsové **náhodné uzly** mají přiřazenou podmíněnou pravděpodobnost stavu pro možné konfigurace rodičů, stejně jak bylo v bayes. síti
- Kosočtvercové **uzly užitku**, (**utility**) mají přiřazenou výplatu (reálné číslo) pro každou konfiguraci rodičů.
- **Hrany do náhodných veličin mají závislostní význam, jako v BN.**
- **Hrany do rozhodovacích uzlů z náhodných veličin mají význam informační:**
- Předpokládáme **nezapomínání** – pokud předchozí rozhodnutí znalo veličinu A, pak ji zná i následné rozhodnutí.
- **Influenční diagram vyžaduje orientovanou cestu přes všechna rozhodnutí**, tj. časové uspořádání na rozhodnutích. (Nevadí, když jsou na cestě i náhodné uzly)

# Influenční diagram (Influence diagram, Decision graph)

**Influenční diagram** je DAG (orientovaný graf bez cyklů) se třemi typy uzlů a dvěma typy tabulek:

- Rozhodovací a náhodné uzly mají konečné množiny vzájemně se vylučujících stavů, uzly užitku nemají žádné stavy.
- Obdélníkové **rozhodovací uzly** nemají přiřazenou tabulku, resp. tabulku podkladů pro rozhodnutí vypočteme
- Elipsové **náhodné uzly** mají přiřazenou podmíněnou pravděpodobnost stavu pro možné konfigurace rodičů, stejně jak bylo v bayes. síti
- Kosočtvercové **uzly užitku**, (**utility**) mají přiřazenu výplatu (reálné číslo) pro každou konfiguraci rodičů.
- Hrany do náhodných veličin mají závislostní význam, jako v BN.
- **Hrany do rozhodovacích uzlů z náhodných veličin mají význam informační: před rozhodnutím známe stav příslušné náhodné veličiny;**  
z rozhodovacích uzlů mají význam časového uspořádání – rozhodnutí, ze kterého jde hrana, musí být uskutečněno dříve, než rozhodnutí – dítě.
- Předpokládáme **nezapomínání** – pokud předchozí rozhodnutí znalo veličinu A, pak ji zná i následné rozhodnutí.
- Influenční diagram vyžaduje orientovanou cestu přes všechna rozhodnutí, tj. časové uspořádání na rozhodnutích. (Nevadí, když jsou na



# Influenční diagram (Influence diagram, Decision graph)

**Influenční diagram** je DAG (orientovaný graf bez cyklů) se třemi typy uzlů a dvěma typy tabulek:

- Rozhodovací a náhodné uzly mají konečné množiny vzájemně se vylučujících stavů, uzly užitku nemají žádné stavy.
- Obdélníkové **rozhodovací uzly** nemají přiřazenou tabulku, resp. tabulku podkladů pro rozhodnutí vypočteme
- Elipsové **náhodné uzly** mají přiřazenou podmíněnou pravděpodobnost stavu pro možné konfigurace rodičů, stejně jak bylo v bayes. síti
- Kosočtvercové **uzly užitku**, (**utility**) mají přiřazenu výplatu (reálné číslo) pro každou konfiguraci rodičů.
- Hrany do náhodných veličin mají závislostní význam, jako v BN.
- **Hrany do rozhodovacích uzlů** z náhodných veličin mají význam informační:
- **Předpokládáme nezapomínání** – pokud předchozí rozhodnutí znalo veličinu A, pak ji zná i následné rozhodnutí.
- Influenční diagram vyžaduje orientovanou cestu přes všechna rozhodnutí, tj. časové uspořádání na rozhodnutích. (Nevadí, když jsou na cestě i náhodné uzly).

# Influenční diagram (Influence diagram, Decision graph)

**Influenční diagram** je DAG (orientovaný graf bez cyklů) se třemi typy uzlů a dvěma typy tabulek:

- Rozhodovací a náhodné uzly mají konečné množiny vzájemně se vylučujících stavů, uzly užitku nemají žádné stavy.
- Obdélníkové **rozhodovací uzly** nemají přiřazenou tabulku, resp. tabulku podkladů pro rozhodnutí vypočteme
- Elipsové **náhodné uzly** mají přiřazenou podmíněnou pravděpodobnost stavu pro možné konfigurace rodičů, stejně jak bylo v bayes. síti
- Kosočtvercové **uzly užitku**, (**utility**) mají přiřazenu výplatu (reálné číslo) pro každou konfiguraci rodičů.
- Hrany do náhodných veličin mají závislostní význam, jako v BN.
- **Hrany do rozhodovacích uzlů** z náhodných veličin mají význam informační:
- Předpokládáme **nezapomínání** – pokud předchozí rozhodnutí znalo veličinu A, pak ji zná i následné rozhodnutí.
- **Influenční diagram vyžaduje orientovanou cestu přes všechna rozhodnutí**, tj. časové uspořádání na rozhodnutích. (Nevadí, když jsou na cestě i náhodné uzly).

## Příklad - Poker (T.D.Nielsen, kniha)

- Každý dostane 5 karet
- poprvé: nejvýše 3 může vyměnit
- podruhé: nejvýše 2 může vyměnit
- můžu 'vsadit' nebo vzdát
- vyšší karty berou talon.

### Úkol

Navrhněte model - rozhodovací graf.

## Vyhodnocení influenčního diagramu

Jedna cesta je vytvořit rozhodovací strom a ten vyhodnotit.

Influenční diagram vyžaduje časové uspořádání rozhodnutí, nechť máme provádět rozhodnutí v pořadí  $D_1, \dots, D_n$ . Označíme  $I_0$  množinu náhodných veličin, které může  $D_1$  pozorovat; obecně  $I_i$  bude množina pozorování, které může pozorovat  $D_{i+1}$ , ale ne  $D_i$ .  $I_n$  jsou pozorování, které nezná ani poslední rozhodnutí. Tím dostáváme částečné časové uspořádání rozhodovacích a náhodných uzlů  $I_0 < D_1 < I_1 < \dots < D_n < I_n$ . Při konstrukci stromu musí být vždy "menší" uzly blíže kořeni.

## Řetězové pravidlo pro influenční diagramy (ID)

Nechť jsou v ID náhodné veličiny  $\mathcal{O}$  a rozhodnutí  $D_1, \dots, D_n$ . Pak:

$$P(\mathcal{O} | D_1, \dots, D_n) = \prod_{X \in \mathcal{O}} P(X | pa(X)).$$

Na základě tohoto pravidla můžeme vypočítat všechny pravděpodobnosti potřebné v rozhodovacím stromě.

# Optimální strategie

Při daném časovém uspořádání  $l_0 < D_1 < l_1 < \dots < D_n < l_n$  je optimální strategie pro  $D_i$ :

$$\sigma_i(l_0, D_1, l_1, \dots, D_{i-1}, l_{i-1}) =$$

$$\operatorname{argmax}_{D_i} \sum_{l_i} \max_{D_{i+1}} \dots \max_{D_n} \sum_{l_n} P(U|D_1, \dots, D_n) V(U, D_1, \dots, D_n)$$

Očekávaná hodnota strategie počínající v  $D_i$  je:

$$\rho_i(l_0, D_1, l_1, \dots, D_{i-1}, l_{i-1}) = \frac{1}{P(l_0, \dots, l_{i-1} | D_1, \dots, D_{i-1})} \cdot$$

$$\max_{D_i} \sum_{l_i} \max_{D_{i+1}} \dots \max_{D_n} \sum_{l_n} P(U|D_1, \dots, D_n) V(U, D_1, \dots, D_n)$$

# Algoritmus eliminace proměnných

- Do seznamu  $\Phi_0$  dáme všechny pravděpodobnostní tabulky  $P(A_i|pa(A_i))$ .
- Do seznamu  $\Psi_0$  dáme všechny tabulky užitku  $V_j(pa(V_j))$ .
- Postupně budeme eliminovat **proti směru časového uspořádání** všechny proměnné. Při eliminaci rozhodnutí si zapamatujeme optimální strategii tohoto rozhodnutí.
- Při použití vyhodnoceného ID nejdříve zadáme hodnoty pozorované před  $D_1$ , pak zvolíme  $d_1$  s největším očekávaným ziskem. Pokračujeme dále zadávání pozorovaných hodnot a volbou rozhodnutí, dokud nedojdeme k poslednímu rozhodnutí.

# Algoritmus eliminace proměnných

- Do seznamu  $\Phi_0$  dáme všechny pravděpodobnostní tabulky  $P(A_i|pa(A_i))$ .
- Do seznamu  $\Psi_0$  dáme všechny tabulky užitku  $V_j(pa(V_j))$ .
- Postupně budeme eliminovat **proti směru časového uspořádání** všechny proměnné. Při eliminaci rozhodnutí si zapamatujeme optimální strategii tohoto rozhodnutí.
- Při použití vyhodnoceného ID nejdříve zadáme hodnoty pozorované před  $D_1$ , pak zvolíme  $d_1$  s největším očekávaným ziskem. Pokračujeme dále zadávání pozorovaných hodnot a volbou rozhodnutí, dokud nedojdeme k poslednímu rozhodnutí.



# Algoritmus eliminace proměnných

- Do seznamu  $\Phi_0$  dáme všechny pravděpodobnostní tabulky  $P(A_i|pa(A_i))$ .
- Do seznamu  $\Psi_0$  dáme všechny tabulky užitku  $V_j(pa(V_j))$ .
- Postupně budeme eliminovat **proti směru časového uspořádání** všechny proměnné. Při eliminaci rozhodnutí si zapamatujeme optimální strategii tohoto rozhodnutí.
- Při použití vyhodnoceného ID nejdříve zadáme hodnoty pozorované před  $D_1$ , pak zvolíme  $d_1$  s největším očekávaným ziskem. Pokračujeme dále zadávání pozorovaných hodnot a volbou rozhodnutí, dokud nedojdeme k poslednímu rozhodnutí.

# Algoritmus eliminace proměnných

- Do seznamu  $\Phi_0$  dáme všechny pravděpodobnostní tabulky  $P(A_i|pa(A_i))$ .
- Do seznamu  $\Psi_0$  dáme všechny tabulky užitku  $V_j(pa(V_j))$ .
- Postupně budeme eliminovat **proti směru časového uspořádání** všechny proměnné. Při eliminaci rozhodnutí si zapamatujeme optimální strategii tohoto rozhodnutí.
- Při použití vyhodnoceného ID nejdříve zadáme hodnoty pozorované před  $D_1$ , pak zvolíme  $d_1$  s největším očekávaným ziskem. Pokračujeme dále zadávání pozorovaných hodnot a volbou rozhodnutí, dokud nedojdeme k poslednímu rozhodnutí.

## Eliminace proměnné $X$ v kroku $i$ znamená:

$$\begin{aligned} ① \quad \Phi_X &= \{\phi \in \Phi_{i-1} \mid X \in \text{dom}(\phi)\} \\ \Psi_X &= \{\psi \in \Psi_{i-1} \mid X \in \text{dom}(\psi)\} \end{aligned}$$

② Je-li  $X$  náhodná veličina

$$\begin{aligned} \phi_X &= \sum_X \Pi \Phi_X \\ \psi_X &= \frac{1}{\phi_X} \sum_X \Pi \Phi_X (\sum \Psi_X) \end{aligned}$$

③ jinak  $X$  rozhodnutí

$$\begin{aligned} \phi_X &= \max_X \Pi \Phi_X \\ \psi_X &= \max_X (\sum \Psi_X) \end{aligned}$$

④ každopádně:

$$\begin{aligned} \Phi_i &= \Phi_{i-1} \setminus \Phi_X \cup \{\phi_X\} \\ \Psi_i &= \Psi_{i-1} \setminus \Psi_X \cup \{\psi_X\} \end{aligned}$$

# Varianty ID

- LIMIDs - Limited Memory IDs
- UUIDs - Unconstrained IDs
- a mnoho jazyků na asymetrické problémy (např. Valuation networks, AIDs)
- CEG - Chain Event Graphs - blíže k rozhodovacím stromům, ale snaží se je maximálně spojovat 'coalescencí'.

Opakování v čase

Příklad: Rybolov

# Varianty ID

- LIMIDs - Limited Memory IDs
- UIDs - Unconstrained IDs
- a mnoho jazyků na asymetrické problémy (např. Valuation networks, AIDs)
- CEG - Chain Event Graphs - blíže k rozhodovacím stromům, ale snaží se je maximálně spojovat 'coalescencí'.

Opakování v čase

Příklad: Rybolov

# Varianty ID

- LIMIDs - Limited Memory IDs
- UUIDs - Unconstrained IDs
- a mnoho jazyků na asymetrické problémy (např. Valuation networks, AIDs)
- CEG - Chain Event Graphs - blíže k rozhodovacím stromům, ale snaží se je maximálně spojovat 'coalescencí'.

Opakování v čase

Příklad: Rybolov

# Varianty ID

- LIMIDs - Limited Memory IDs
- UUIDs - Unconstrained IDs
- a mnoho jazyků na asymetrické problémy (např. Valuation networks, AIDs)
- CEG - Chain Event Graphs - blíže k rozhodovacím stromům, ale snaží se je maximálně spojovat 'coalescencí'.

Opakování v čase

Příklad: Rybolov

# Varianty ID

- LIMIDs - Limited Memory IDs
- UUIDs - Unconstrained IDs
- a mnoho jazyků na asymetrické problémy (např. Valuation networks, AIDs)
- CEG - Chain Event Graphs - blíže k rozhodovacím stromům, ale snaží se je maximálně spojovat 'coalescencí'.

Opakování v čase

Příklad: Rybolov



# Markovské rozhodovací procesy

- Předpokládáme, že se množina možných stavů  $S$  nemění v průběhu času
- **Markovská vlastnost** stav v čase  $t + 1$  je nezávislý na stavu v čase  $t - i$ ,  $i > 0$  při znalosti stavu v čase  $t$ , tj.

$$S_{t+1} \perp\!\!\!\perp S_{t-i} | S_t$$

- Toto jsou plně pozorované markovské procesy prvního řádu; markovské procesy vyššího řádu dovolují závislost na více předchozích stavech.

# Markovské rozhodovací procesy

- Předpokládáme, že se množina možných stavů  $S$  nemění v průběhu času
- **Markovská vlastnost** stav v čase  $t + 1$  je nezávislý na stavu v čase  $t - i$ ,  $i > 0$  při znalosti stavu v čase  $t$ , tj.

$$S_{t+1} \perp\!\!\!\perp S_{t-i} | S_t$$

- Toto jsou plně pozorované markovské procesy prvního řádu; markovské procesy vyššího řádu dovolují závislost na více předchozích stavech.

# Markovské rozhodovací procesy

- Předpokládáme, že se množina možných stavů  $S$  nemění v průběhu času
- **Markovská vlastnost** stav v čase  $t + 1$  je nezávislý na stavu v čase  $t - i$ ,  $i > 0$  při znalosti stavu v čase  $t$ , tj.

$$S_{t+1} \perp\!\!\!\perp S_{t-i} | S_t$$

- Toto jsou plně pozorované markovské procesy prvního řádu; markovské procesy vyššího řádu dovolují závislost na více předchozích stavech.

# Markovský rozhodovací proces MDP

- Množina stavů  $S$  v každém časovém bodě stejná
- Počáteční stav  $s_0$
- Množina možných akcí  $A$
- Matice přechodu  $T(s, a, s')$
- Výplata v každém stavu  $R(s)$

# Kumulovaná výplata

Protože jde o proces v čase, výplaty musíme sčítat.

Jsou dvě možnosti:

- MDP s konečným horizontem – předem stanoví počet kroků
- nekonečný proces a součet, ale hodnoty v budoucnosti budeme počítat s nižší hodnotou (kdo ví, co bude pak).

Zvolíme tzv. **diskontní faktor**  $\gamma$ ,  $0 < \gamma < 1$ , a maximalizujeme

$$U(s_0, \dots, s_t, \dots) = \sum_{t=0}^{\infty} \gamma^t R(s_t)$$

- $\gamma$  odpovídá úrokové míře  $\frac{1}{\gamma} - 1$ , kterou musíme platit.
- Vzhledem ke konečnosti  $S$  je  $U(s_0, \dots, s_t, \dots) \leq \frac{R_{max}}{(1-\gamma)}$

# Kumulovaná výplata

Protože jde o proces v čase, výplaty musíme sčítat.

Jsou dvě možnosti:

- MDP s konečným horizontem – předem stanoví počet kroků
- nekonečný proces a součet, ale hodnoty v budoucnosti budeme počítat s nižší hodnotou (kdo ví, co bude pak).

Zvolíme tzv. **diskontní faktor**  $\gamma$ ,  $0 < \gamma < 1$ , a maximalizujeme

$$U(s_0, \dots, s_t, \dots) = \sum_{t=0}^{\infty} \gamma^t R(s_t)$$

- $\gamma$  odpovídá úrokové míře  $\frac{1}{\gamma} - 1$ , kterou musíme platit.
- Vzhledem ke konečnosti  $S$  je  $U(s_0, \dots, s_t, \dots) \leq \frac{R_{max}}{(1-\gamma)}$

# Kumulovaná výplata

Protože jde o proces v čase, výplaty musíme sčítat.

Jsou dvě možnosti:

- MDP s konečným horizontem – předem stanoví počet kroků
- nekonečný proces a součet, ale hodnoty v budoucnosti budeme počítat s nižší hodnotou (kdo ví, co bude pak).

Zvolíme tzv. **diskontní faktor**  $\gamma$ ,  $0 < \gamma < 1$ , a maximalizujeme

$$U(s_0, \dots, s_t, \dots) = \sum_{t=0}^{\infty} \gamma^t R(s_t)$$

- $\gamma$  odpovídá úrokové míře  $\frac{1}{\gamma} - 1$ , kterou musíme platit.
- Vzhledem ke konečnosti  $S$  je  $U(s_0, \dots, s_t, \dots) \leq \frac{R_{\max}}{(1-\gamma)}$

# Kumulovaná výplata

Protože jde o proces v čase, výplaty musíme sčítat.

Jsou dvě možnosti:

- MDP s konečným horizontem – předem stanoví počet kroků
- nekonečný proces a součet, ale hodnoty v budoucnosti budeme počítat s nižší hodnotou (kdo ví, co bude pak).

Zvolíme tzv. **diskontní faktor**  $\gamma$ ,  $0 < \gamma < 1$ , a maximalizujeme

$$U(s_0, \dots, s_t, \dots) = \sum_{t=0}^{\infty} \gamma^t R(s_t)$$

- $\gamma$  odpovídá úrokové míře  $\frac{1}{\gamma} - 1$ , kterou musíme platit.
- Vzhledem ke konečnosti  $S$  je  $U(s_0, \dots, s_t, \dots) \leq \frac{R_{\max}}{(1-\gamma)}$



# Strategie (policy)

Cílem je najít takovou **strategii**  $\pi^*$ , která maximalizuje očekávanou výplatu, tj.

$$\pi^* = \operatorname{argmax}_{\pi} E \left[ \sum_{t=0}^{\infty} \gamma^t R(s_t) \mid \pi \right]$$

- Konečný horizont vede k **nestacionární** strategii, tj. různé strategii dle toho, kolik času zbývá do konce.
- Nekonečný horizont vede ke **stacionární** strategii, tj. doporučený tah v políčku (stavu) je stejný nezávisle na počtu již provedených tahů.
- Reprezentovat stacionární strategii je snazší.
- Máme-li jistotu, že agent musí skončit v cílovém stavu, můžeme počítat s  $\gamma = 1$ , jinak bychom mohli neustále zvyšovat užitek a neměli bychom zajištěno nalezení optimální strategie. (Šlo by hledat maximální zisk za  $k$  kroků.)

# Strategie (policy)

Cílem je najít takovou **strategii**  $\pi^*$ , která maximalizuje očekávanou výplatu, tj.

$$\pi^* = \operatorname{argmax}_{\pi} E \left[ \sum_{t=0}^{\infty} \gamma^t R(s_t) \mid \pi \right]$$

- Konečný horizont vede k **nestacionární** strategii, tj. různé strategii dle toho, kolik času zbývá do konce.
- Nekonečný horizont vede ke **stacionární** strategii, tj. doporučený tah v políčku (stavu) je stejný nezávisle na počtu již provedených tahů.
- Reprezentovat stacionární strategii je snazší.
- Máme-li jistotu, že agent musí skončit v cílovém stavu, můžeme počítat s  $\gamma = 1$ , jinak bychom mohli neustále zvyšovat užitek a neměli bychom zajištěno nalezení optimální strategie. (Šlo by hledat maximální zisk za  $k$  kroků.)

# Strategie (policy)

Cílem je najít takovou **strategii**  $\pi^*$ , která maximalizuje očekávanou výplatu, tj.

$$\pi^* = \operatorname{argmax}_{\pi} E \left[ \sum_{t=0}^{\infty} \gamma^t R(s_t) \mid \pi \right]$$

- Konečný horizont vede k **nestacionární** strategii, tj. různé strategii dle toho, kolik času zbývá do konce.
- Nekonečný horizont vede ke **stacionární** strategii, tj. doporučený tah v políčku (stavu) je stejný nezávisle na počtu již provedených tahů.
- Reprezentovat stacionární strategii je snazší.
- Máme-li jistotu, že agent musí skončit v cílovém stavu, můžeme počítat s  $\gamma = 1$ , jinak bychom mohli neustále zvyšovat užitek a neměli bychom zajištěno nalezení optimální strategie. (Šlo by hledat maximální zisk za  $k$  kroků.)

# Strategie (policy)

Cílem je najít takovou **strategii**  $\pi^*$ , která maximalizuje očekávanou výplatu, tj.

$$\pi^* = \operatorname{argmax}_{\pi} E \left[ \sum_{t=0}^{\infty} \gamma^t R(s_t) \mid \pi \right]$$

- Konečný horizont vede k **nestacionární** strategii, tj. různé strategii dle toho, kolik času zbývá do konce.
- Nekonečný horizont vede ke **stacionární** strategii, tj. doporučený tah v políčku (stavu) je stejný nezávisle na počtu již provedených tahů.
- Reprezentovat stacionární strategii je snazší.
- Máme-li jistotu, že agent musí skončit v cílovém stavu, můžeme počítat s  $\gamma = 1$ , jinak bychom mohli neustále zvyšovat užitek a neměli bychom zajištěno nalezení optimální strategie. (Šlo by hledat maximální zisk za  $k$  kroků.)

# Algoritmus řešení MDP Iterací hodnot

input: MDP, stavy  $S$ , přechody  $T$ , výplata  $R$ , diskontní f.  $\gamma, \epsilon$

prom.:  $U, U^1$ , vektory užitku stavů v  $S$ , na poč. 0

$\delta$  maximální změna užitku v jedné iteraci

repeat

$U \leftarrow U^1; \delta \leftarrow 0$

for each state  $s$  in  $S$  do

$U^1[s] \leftarrow R[s] + \gamma \max_a \sum_{s'} T(s, a, s') U(s')$

if  $|U^1[s] - U[s]| > \delta$  then  $\delta \leftarrow |U^1[s] - U[s]|$

until  $\delta < \epsilon(1 - \gamma)/\gamma$

return  $U$

# Iterace strategie (policy iteration)

input: MDP, stavy  $S$ , přechody  $T$ , výplata  $R$ , diskontní f.  $\gamma, \epsilon$   
prom.:  $U$ , vektory užitku stavů v  $S$ , na poč. 0

$\pi$  strategie, na začátku náhodná

**repeat**

$U \leftarrow \text{HODNOTA\_STRATEGIE}(\pi, U, \text{MPD})$

$unchanged? \leftarrow true$

**for each** state  $s$  in  $S$  **do**

**if**  $\max_a \sum_{s'} T(s, a, s') U[s'] > \sum_{s'} T(s, \pi[s], s') U[s']$

**then**

$\pi[s] \leftarrow \operatorname{argmax}_a \sum_{s'} T(s, a, s') U[s']$

$unchanged? \leftarrow false$

**until**  $unchanged?$

**return**  $\pi$

Výpočet  $\text{HODNOTA\_STRATEGIE}(\pi, U, \text{MPD})$  vyžaduje vyřešení soustavy  $|S|$  lineárních rovnic pro  $U[s]$  v jednotlivých stavech.

# Částečně pozorovatelné markovské procesy (POMDP)

- nejsme schopni pozorovat stav, pouze skrze nepřesné senzory.
- Bude příště.
- Pointy:
  - Proces je opět makrovský, pokud bereme BELIEF (PRAVDĚPODOBNOSTNÍ ROZLOŽENÍ) na stavech. Těch je ale nekonečně, tedy máme problém.
  - Tzv. Witness algoritmus – hledáme svědka, že naše strategie není optimální.