

Jiná pravděpodobnostní rozložení a typy modelů

- ▶ Vícerozměrné normální rozložení $y = (y_1, \dots, y_k)$
- ▶
$$\phi(y) = \frac{1}{\sqrt{|2\pi\Sigma|}} e^{-\frac{1}{2}(y-\mu)\Sigma^{-1}(y-\mu)}$$
 - ▶ $|\cdot|$ je determinant, pokud počet složek y označíme k je $|2\pi\Sigma| = (2\pi)^k |\Sigma|$.
- ▶ pokud Σ není invertibilní, má závislé sloupce, tj. proměnné y_i jsou lineárně závislé.
 - ▶ vezmeme hodnotu matice Σ (označ. ℓ), pak existuje matice A a vektor ν , že
 - ▶ $y = Az + \nu$ pro ℓ dimenzionální nové souřadnice z
 - ▶ my: přejdeme k novým souřadnicím, pro které má Σ plnou hodnotu.

Marginalizace

- ▶ Máme: $\frac{1}{\sqrt{|2\pi\Sigma|}} e^{-\frac{1}{2}(y-\mu)\Sigma^{-1}(y-\mu)}$
- ▶ chceme: rozložení na veličinách $\{y_3, y_5, y_7\} \subset \{y_1, \dots, y_n\}$
- ▶ marginální rozložení dostaneme, když 'nezajímavé' dimenze prostě vynecháme, tj.
- ▶ $\mu_{3,5,7} = (\mu_3, \mu_5, \mu_7)$ a $\Sigma_{3,5,7} = \begin{bmatrix} \Sigma_{33} & \Sigma_{35} & \Sigma_{37} \\ \Sigma_{53} & \Sigma_{55} & \Sigma_{57} \\ \Sigma_{73} & \Sigma_{75} & \Sigma_{77} \end{bmatrix}$
- ▶ tj. $\frac{1}{\sqrt{|2\pi\Sigma_{3,5,7}|}} e^{-\frac{1}{2}(y_{3,5,7}-\mu_{3,5,7})\Sigma_{3,5,7}^{-1}(y_{3,5,7}-\mu_{3,5,7})}$

Podmiňování

- ▶ Zajímá nás $\pi(A|B)$, kde
 - ▶ $A \subset \{y_1, \dots, y_n\}$ o q prvcích,
 - ▶ zbytek $B = \{y_1, \dots, y_n\} \setminus A$ má $(n - q)$ prvků.
- ▶ přeházíme řádky (a sloupce), aby A byly u sebe, pak všechna B ;
dostaneme: $y = \begin{bmatrix} y_A \\ y_B \end{bmatrix}$ (1 sloupec), $\mu = \begin{bmatrix} \mu_A \\ \mu_B \end{bmatrix}$ (1 sloupec),
 $\Sigma = \begin{bmatrix} \Sigma_{AA} & \Sigma_{AB} \\ \Sigma_{BA} & \Sigma_{BB} \end{bmatrix}$ o dimenzích $\begin{bmatrix} q \times q & q \times (n - q) \\ (n - q) \times q & (n - q) \times (n - q) \end{bmatrix}$.
- ▶ Parametry podmíněného normálního rozložení
 $\pi(A|B = b) = N(\mu_{A|B=b}, \Sigma_{A|B=b})$ jsou:

$$\mu_{A|B=b} = \mu_A + \Sigma_{AB} \Sigma_{BB}^{-1} (b - \mu_B)$$

$$\Sigma_{A|B=b} = \Sigma_{AA} - \Sigma_{AB} \Sigma_{BB}^{-1} \Sigma_{BA}$$

Přidání nové složky y_{n+1}

- ▶ Pokud chceme do modelu přidat proměnnou y_{n+1} , stále předpokládáme vícerozměrné gaussové
- ▶ přidáme lineární funkci průměru (střední hodnoty):
 - ▶ $\mu_{y_{n+1}|y_1, \dots, n} = c_0 + \sum_{i=1, \dots, n} c_i y_i$
 - ▶ rozptyl $\sigma_{(n+1)}^2$
 - ▶ případně kovariance k ostatním veličinám.

Se gaussovsky rozloženými veličinami můžeme dělat 'totéž' (grafický model, rozklad, propagace) jako v diskretním.

Změníme parametrizaci rozložení

- ▶ Gaussovské rozložení $\phi(y) = \frac{1}{\sqrt{|2\pi\Sigma|}} e^{-\frac{1}{2}(y-\mu)\Sigma^{-1}(y-\mu)}$
- ▶ definujeme:
 - ▶ koncentrační matice $K = \Sigma^{-1}$
 - ▶ $h = K\mu$
 - ▶ $a = -\frac{d}{2} \log(2\pi) + \frac{1}{2} \log(|K|) - \frac{1}{2} \mu^T K \mu$
- ▶ pak vícerozměrnou gaussovskou hustotu přepíšeme

$$\begin{aligned}\phi(y) &= (2\pi)^{-\frac{d}{2}} |K|^{\frac{1}{2}} \exp \left\{ -\frac{1}{2} (y - \mu)^T K (y - \mu) \right\} \\&= (2\pi)^{-\frac{d}{2}} |K|^{\frac{1}{2}} \exp \left\{ -\frac{1}{2} \mu^T K \mu + h^T y - \frac{1}{2} y^T K y \right\} \\&= \exp \left\{ a + h^T y - \frac{1}{2} y^T K y \right\} \\&= \exp \left\{ a + \sum_u h_u y_u - \frac{1}{2} \sum_{u,v} K_{u,v} y_u y_v \right\}\end{aligned}$$

Rozložitelnost

- ▶ $\phi(y) = \exp \left\{ a + \sum_{u \in U} h_u y_u - \frac{1}{2} \sum_{u,v} K_{u,v} y_u y_v \right\}$
 - ▶ Mějme množiny vrcholů A, B separované množinou C . Pak máme $\forall u \in A, v \in B \ k_{uv} = 0$.
 - ▶ Podíváme se na vzorec a sumy rozdělíme: $\phi(y) = \exp \left\{ \begin{array}{l} a + \sum_{u \in A \cup C} h_u y_u + \sum_{v \in B \cup C} h_v y_v - \sum_{v \in C} h_v y_v \\ - \frac{1}{2} (\sum_{u,v \in A \cup C} K_{u,v} y_u y_v + \sum_{u,v \in B \cup C} K_{u,v} y_u y_v - \sum_{u,v \in C} K_{u,v} y_u y_v) \end{array} \right\}$
- | | A | C | B |
|---|----------|----------|----------|
| A | K_{AA} | K_{AC} | |
| C | K_{AC} | K_{CC} | K_{CB} |
| B | | K_{BC} | K_{BB} |
- ▶ Tedy $\phi(y) = g(A, C)h(C, B)$

Diskrétní veličiny

- ▶ Mějme tři veličiny, A, B, C , libovolnou pravděpodobnostní distribuci $p(A, B, C)$ (velkým proměnná, malým konkrétní hodnota) můžeme zapsat pomocí (neznámých) parametrů u_* , tzv. *interaction terms*:
 - ▶ $\log(p(a, b, c)) = u + u_a^A + u_b^B + u_c^C + u_{ab}^{AB} + u_{ac}^{AC} + u_{bc}^{BC} + u_{abc}^{ABC}$
(u je víc než je třeba, protože ...)
 - ▶ aby prošlo i pro nulu, napíšeme v exponenciálním tvaru $\tilde{u} = \exp u$:
 - ▶ $p(a, b, c) = \tilde{u} \cdot \tilde{u}_a^A \cdot \tilde{u}_b^B \cdot \tilde{u}_c^C \cdot \tilde{u}_{ab}^{AB} \cdot \tilde{u}_{ac}^{AC} \cdot \tilde{u}_{bc}^{BC} \cdot \tilde{u}_{abc}^{ABC}$
- ▶ log-lineární modely některé interakce z u_* dají napevno rovné nule
 - ▶ s úmluvou, že pokud dám rovno nule u_{AB} , tak i všechny vyšší interakce u^{ABC} atd. musí být rovny nule.
 - ▶ pro specifikaci hierarchického modelu stačí zadat maximální interakce, tzv. generátory.
 - ▶ např. $\{a, b\}$ a $\{a, c\}$ generují model:
 - ▶ $\log(p(a, b, c)) = u + u_a^A + u_b^B + u_c^C + u_{ab}^{AB} + u_{ac}^{AC}$ (jedno-složkové interakce jsou tam proto, že jsou podmnožinou více-složkového generátoru).

Faktorizace

- ▶ $\log(p(a, b, c)) = u + u_a^A + u_b^B + u_c^C + u_{ab}^{AB} + u_{ac}^{AC}$
- ▶ $p(a, b, c) = \tilde{u} \cdot \tilde{u}_a^A \cdot \tilde{u}_b^B \cdot \tilde{u}_c^C \cdot \tilde{u}_{ab}^{AB} \cdot \tilde{u}_{ac}^{AC}$
- ▶ model výše lze rozepsat na součin:
- ▶ $p(a, b, c) = (\tilde{u} \cdot \tilde{u}_a^A \cdot \tilde{u}_b^B \cdot \tilde{u}_{ab}^{AB}) \cdot (\tilde{u}_c^C \cdot \tilde{u}_{ac}^{AC})$
- ▶ Vidíte tam podmíněnou nezávislost $B \perp\!\!\!\perp C | A$?
- ▶ obecně: dva faktory jsou nezávislé dano zbytek právě když interakce této dvojice je nuceně 0 (tj. nevyskytují se spolu v žádné interakci)
- ▶ graf: hrana právě když je interakce dvojice povolena (ne–nutně–nula).
- ▶ grafické modely: log–lineární modely s generátory definovanými klikami grafu.
- ▶ Najděte log–lineární model, který není grafický.
- ▶ Obecně je třeba log–lineární modely učit iterativně i pro plná data.
- ▶ Pro rozložitelné modely existuje přímý výpočet. Rozložitelný model: lze rozebrat tak, že vždy eliminujeme simplicialní uzel, existuje perfektní eliminační posloupnost, graf je triangulovaný (kružnice délky 4 a víc mají tětívu).
- ▶ Najděte grafický model, který není rozložitelný.

Mixed interaction models

- ▶ A teď diskrétní a gaussovské dohromady.
- ▶ *podmíněná gaussovská hustota* pro $x(i, y)$, i seznam diskrétních proměnných, y seznam spojitých proměnných
- ▶ $f(i, y) = p(i)(2\pi)^{-\frac{q}{2}}|\Sigma|^{-\frac{1}{2}}\exp(-\frac{1}{2}(y - \mu(i))\Sigma^{-1}(y - \mu(i)))$
- ▶ parametry $p(i), \mu(i), i \in \mathcal{I}, \Sigma$ se nazývají *moment parameters*
- ▶ když rovnici převedeme do tvaru 'exponenciálních rodní'

$$\begin{aligned}f(i, y) &= \exp \left\{ g(i) + h(i)^T y - \frac{1}{2} y^T K y \right\} \\&= \exp \left\{ g(i) + \sum_u h_u(i) y_u - \frac{1}{2} \sum_{u,v} K_{u,v} y_u y_v \right\}\end{aligned}$$

- ▶ parametry $g(i), h(i), i \in \mathcal{I}, K$ se nazývají *kanonické parametry*

Mixed interaction models

- ▶ Marginála už nemusí být podmíněná gaussovská hustota (je to směs gaussovských hustot)
- ▶ ještě pořád se s tím dá počítat
 - ▶ za předpokladu, že všechny diskrétní veličiny jsou 'u sebe'
 - ▶ tj. pokud existuje cesta mezi diskrétními veličinami, existuje i jejich neobsahující spojitý uzel
 - ▶ pak lze počítat likelihood a učit model.

Exponenciální rodiny

- ▶ distribuční funkce ve tvaru

$$p(x) = h(x)e^{\theta^T T(x) - A(\theta)}$$

- ▶ nebo obecněji ve tvaru

$$p(x) = h(x)e^{\eta(\theta)^T T(x) - A(\eta(\theta))}$$

- ▶ θ vektor parametrů
- ▶ η natural parameters
- ▶ $T(x)$ sufficient statistics
- ▶ $A(\theta)$ – normalizační funkce
- ▶ $h(x)$
- ▶ klíčová myšlenka: θ a x jsou společně jen v $e^{\theta^T T(x)}$

Příklady rozložení z exponenciálních rodin

(tj. dají se 'reparametrizovat')

Gaussian $\phi(y) = \frac{1}{\sqrt{|2\pi\Sigma|}} e^{-\frac{1}{2}(y-\mu)\Sigma^{-1}(y-\mu)} \quad x \in R$

Bernoulli $p(x) = \alpha^x(1-\alpha)^{1-x} \quad x \in \{0, 1\}$

Binomial $p(x) = \binom{n}{x} \alpha^x(1-\alpha)^{n-x} \quad x \in \{0, 1, \dots, n\}$

Multinomial $p(x) = \frac{n!}{x_1!x_2!\dots x_n!} \prod_{i=1}^n \alpha_i^{x_i} \quad x \in \{0, 1, \dots, n\}, \sum_i x_i = n$

Exponential $p(x) = \lambda e^{-\lambda x} \quad x \in R^+$

Poisson $p(x) = \frac{e^{-\lambda} \lambda^x}{x!} \quad x \in \{0, 1, \dots\}$

Dirichlet $p(x) = \frac{\Gamma(\sum_i \alpha_i)}{\prod_i \Gamma(\alpha_i)} \prod_i x_i^{\alpha_i-1} \quad x \in <0, 1>, \sum_i x_i = 1$

► $\Gamma(k) = k!, \Gamma(z) = \int_0^\infty x^{z-1} e^{-x} dx$

Příklad: USA senát: hledání skupin podobně hlasujících

Justin Grimmer: An Introduction to Bayesian Inference via Variational Approximations

- ▶ N senátorů $i = 1, \dots, N$.
- ▶ každý v právě jednom z K klastrů $k = 1, \dots, K$ podobně hlasujících
- ▶ τ_i je K rozměrný vektor, indikuje klast i -tého senátora
- ▶ pravděpodobnost klastrů (bloků) π
- ▶ pravděpodobnost i -tý senátor v bloku k : $\tau_i | \pi \approx \text{Multinomial}(1, \pi)$
- ▶ pozorovali jsme J hlasování
 - ▶ každé hlasování má pro každý blok parametr 'pravděpodobnost pozitivního hlasování'
 $\theta_k = (\theta_{k1}, \dots, \theta_{kJ})$
- ▶ i -tý senátor (v bloku $\tau_{ik} = 1$), j -té hlasování
 - ▶ $V_{ij} | \tau_{ik} = 1 \approx \text{Bernoulli}(\theta_{kj})$
- ▶ apriorní rozložení předpokládáme
 - ▶ $\pi \approx \text{Dirichlet}(\alpha)$
 - ▶ $\forall k, j \theta_{kj} \approx \text{Beta}(\gamma_1, \gamma_2)$

'Běžné metody'

- ▶ MCMC vzorkování má problém
 - ▶ pro různé permutace 'identifikátorů bloků' stejný výsledek i likelihood
 - ▶ snadno může přeskakovat a nedržet se jednoho konkrétního
 - ▶ pak jsou napočtené četnosti i hodně daleko od reality
- ▶ EM klastrování
 - ▶ hodně parametrů (s každým hlasováním další)
 - ▶ potřebuje invertovat matici $218,694 \times 218,694$
 - ▶ potřebuje hodně dat
 - ▶ senátorů ale není neomezeně
- ▶ EM v M kroku počítá maximálně věrohodný model = JEDEN
- ▶ následující algoritmus bude držet (přibližné) rozložení na 'všech' modelech

Variational approximation

- ▶ Chceme 'posterior' $p(model|data) = p(\theta, \pi, \tau)$
- ▶ aproximujeme pomocí $q(\theta, \pi, \tau)$
- ▶ a předpokládáme nezávislost parametrů,
 $q(\theta, \pi, \tau) = q(\pi) \prod_{k=1}^K \prod_{j=1}^J q(\theta_{kj}) \prod_{i=1}^N q(\tau_i)$
- ▶ předpokládáme rozložení (viz dříve)
 - ▶ $q(\tau_i) = \text{Multinomial}(1, r_i)$, kde $r_i = (r_{i1}, \dots, r_{iK})$
 - ▶ $q(\pi) = \text{Dirichlet}(\lambda)$, kde $\lambda = (\lambda_1, \dots, \lambda_K)$
 - ▶ $\forall k, j \ q(\theta_{kj}) = \text{Beta}(\eta_{kj1}, \eta_{kj2})$
- ▶ iterujeme podobně jako v EM, jen minimalizujeme KL divergenci $KL(q(), p(|data))$.
- ▶ Máme $\lambda_k^{old}, \theta_{kj}^{old}$, chceme r_{ik}^{new} :

$$r_{ik}^{new} \propto \exp \left\{ E(\log \pi_k) \sum_{j=1}^J \{ V_{ij} (E(\log \theta_{kj1})) + (1 - V_{ij}) (E(\log \theta_{kj2})) \} \right\}$$

where $E[\log \pi_k] = \Psi(\lambda_k^{old}) - \Psi(\sum_{z=1}^K \lambda_z^{old})$, $E[\log \theta_{kj1}] = \Psi(\eta_{kj1}^{old}) - \Psi(\eta_{kj1}^{old} + \eta_{kj2}^{old})$, and $E[\log \theta_{kj2}] = \Psi(\eta_{kj2}^{old}) - \Psi(\eta_{kj1}^{old} + \eta_{kj2}^{old})$. $\Psi(\cdot)$ is the *Digamma* function, the derivative of the *Gamma* function. Next, we set λ_k^{new} to $\lambda_k^{new} = \alpha_k + \sum_{i=1}^N r_{ik}^{new}$. And finally, we set θ_{kj}^{new} to, $\theta_{kj1}^{new} = \gamma_1 + \sum_{i=1}^N r_{ik}^{new} V_{ij}$ and $\theta_{kj2}^{new} = \gamma_2 + \sum_{i=1}^N r_{ik}^{new} (1 - V_{ij})$.

$$\Psi(x) = \frac{\Gamma'(x)}{\Gamma(x)}$$

Příklad: USA senát: hledání skupin podobně hlasujících

Table 1 Voting blocs in U.S. Senate

<i>Label</i>	<i>Example senators</i>	<i>Distinctive Vote</i>	<i>%</i>
Cons. Rep	Coburn, DeMint, Inhofe, Sessions	Amendment 521: Reduce Federal Debt	37.7
Mod. Rep	Coleman, Hagel, Lugar, Murkowski	Amendment 2662: Prohibit Canyon Funds	12.2
Mod. Dem	Bayh, McCaskill, Lieberman, Ben Nelson	Cloture on S. 2633: Iraq Redeployment	17.0
Lib. Dem	Clinton, Kennedy, Obama, Sanders	Table Amendment 4388: Mortgages	33.0

Součin členů exp. rodin

- ▶ součin dvou členů exp. rodin je také z exp. rodin,
- ▶ ale nemusí mít hezkou parametrickou formu

$$h(x)e^{\theta_1^T T(x) - A(\theta_1)} \cdot h(x)e^{\theta_2^T T(x) - A(\theta_2)} = \tilde{h}(x)e^{(\theta_1 + \theta_2)^T T(x) - \tilde{A}(\theta_1, \theta_2)}$$

- ▶ součet dvou členů exp. rodin už do exp. rodin patřit nemusí.

Bayesovské rozhodování, konjugované hustoty

- ▶ $p(\theta|x) = \frac{p(x|\theta)p(\theta)}{\int p(x|\theta)p(\theta)d\theta}$
- ▶ máme-li 'hezké' $p(\theta)$ a $p(x|\theta)$, součin $p(x|\theta)p(\theta)$ už být hezký nemusí
- ▶ ale může: když zvolíme vhodné hustoty
- ▶ Dirichlet a Multinomial
- ▶ gausovské a gausovské
- ▶ beta a bernoulli
- ▶ a další.